

Efficient Posterior Inference for Bayesian Semi-Supervised Keyphrase Extraction Using the AWSGLD Algorithm

BSS 키프레이즈 추출에 AWSGLD 사후 샘플링을 결합하여, 사후분포의 로컬 트랩 탈출과 수렴 효율 개선

홍지윤 | 소속: 고려대학교 빅데이터사이언스학과 | 지도교수: 전수영

1 배경 및 필요성

- 배경:** 그래프 기반 BSS 모델 (Wang et al., 2023) 은 소수의 관찰 라벨로 keyphrase 의 사후확률을 추정하는 준지도 추출 프레임워크이다.
- 필요성:** BSS 의 다봉 사후분포에서 기존 acMH 샘플러는 로컬 트랩에 갇혀 중요도 점수를 제대로 복원하지 못한다.
- 목표:** AWSGLD 를 θ 샘플링에 도입한 BSS-AWSGLD 를 제안하고, 탈출 능력 · 확장성 · 수렴성을 검증한다.

2 BSS · 베이지안 준지도 키프레이즈 추출

- 그래프 구성:** 문서의 후보 구 (1-4 그램) 로 동시출현 그래프 A 와 차수행렬 D 를 만들고, 전이행렬 $G=D^{-1}A$ 로 구 간 연결 구조를 인코딩한다.
- 모델:** 구 i 의 잠재 중요도 θ_i 를 logit 링크로 관측 확률 $\pi_i = \sigma(\theta_i)$ 에 연결한다.
- 가능도 (PU):** 관측 양성은 모두 참 양성이며, α 는 참 키프레이즈가 미관측될 결측률이다.
$$P(y|\pi, \alpha) = \prod_i [(1-\alpha)\pi_i]^{y_i} [1-\pi_i+\alpha\pi_i]^{1-y_i}$$
- 사전분포:** 그래프 구조를 반영해 인접 구의 중요도가 매끄럽게 변하도록 정규분포 사전분포를 둔다.
$$\theta \sim N(u_0, B^{-1}(B^{-1})^T \sigma^2)$$
$$B = I - dG^T \text{ (그래프 결합행렬)}, u_0 = B^{-1}(1-d)\mathbb{1} \text{ (TextRank 사전 중심)}, d = 0.85.$$

3 제안 · BSS-AWSGLD

- 교체 원리.** 원 BSS 의 추론 루프에서 θ 샘플링 스텝을 AWSGLD 로 교체한다 (σ^2 Gibbs- α 갱신 · 모델 구조 유지).
- 트랩 탈출 메커니즘.** 사후 에너지를 m 개 구간으로 분할하고, 방문 빈도가 낮은 저에너지 구간에 큰 기울기 배율을 부여해 모드 간 장벽을 평탄화함으로써 체인이 로컬 트랩을 탈출하도록 한다.




그림 1. 가중 완화 에너지 지형: 장벽 평탄화 + 최소점 집중 (Deng et al., 2022)

Algorithm. BSS-AWSGLD sampler

```
1: Input: 온도  $\tau$ , 가중 스케일  $\zeta$ , 구간 수  $m$ , 학습률  $\{\epsilon_k\}$ , 가중 갱신 step  $\{\omega_k\}$ , 반복 수  $T$ .
2: Initialize:  $\theta^{(0)} \leftarrow \text{logit}(B_*^{-1}Y)$ ,  $\alpha_0 \leftarrow$  격자 MLE,  $\psi_0(i) = i/m$ .
3: for  $k = 0, \dots, T-1$  do
4:   (Gibbs)  $\sigma_k^2 \sim \text{IG}(n/2+0.001, C/2+0.001)$ ,  $C = \|B(\theta_k - u_0)\|^2$ .
5:   확률적 에너지  $\tilde{U}(\theta_k) = -\sum_i [y_i \log((1-\alpha)\sigma(\theta_i)) + (1-y_i)\log(1-(1-\alpha)\sigma(\theta_i))] + C/(2\sigma_k^2)$  와 기울기  $\nabla \tilde{U}$  계산.
6:   부분영역 인덱스  $\tilde{J}_k = \lfloor (\tilde{U}(\theta_k) - E_{\min}) / \Delta u \rfloor$  결정.
7:   (AWSGLD)  $\theta_{k+1} = \theta_k - \epsilon_k [1 + (\zeta \tau / \Delta u) (\log \psi(\tilde{J}_k) - \log \psi(\tilde{J}_k - 1))] \nabla \tilde{U}(\theta_k) + \sqrt{(2\tau \epsilon_k)} \cdot e_k$ ,  $e_k \sim N(0, I_n)$ . (Deng et al., 2022)
8:   (SA update)  $\psi(i) \leftarrow \psi(i) + \omega_k \psi(\tilde{J}_k) (\mathbb{1}_{\{i \geq \tilde{J}_k\}} - \psi(i))$ ,  $i = 1, \dots, m$ .
9:    $\alpha$  갱신 (격자 MLE).
10: end for
11: Output: burn-in 이후  $\pi_i = \sigma(\theta_i)$  사후 median, FDR 컷오프로 키프레이즈 선별.
 $\epsilon_k$ : 학습률,  $\omega_k$ : 가중 갱신 step,  $\tau$ : 온도,  $\zeta$ : 가중 스케일,  $\Delta u$ : 에너지 구간 폭,  $m$ : 구간 수,  $\psi$ : 적응 가중,  $\tilde{J}$ : 부분영역 인덱스.
```

4 모의실험 설계

- 동일한 합성 그래프 · $\theta^* \cdot Y$ 초기값 하에서 5 개 샘플러를 비교한다

구분	목적	핵심 설정
Study 1A/1B	난이도별 견고성 · 로컬 트랩 진단	4 시나리오 × 5 샘플러, 다봉 trap
Study 2	표본 확장성 (빅데이터)	$n = 200 / 1500 / 10000$
Study 3	수렴 진단	4-패널 진단

평가 지표: 척도 의존적 MSE 단독 대신 Spearman- $\hat{R}$ max·Cost/ESS·NDCG@k 를 사용한다.

5 Study 1A · 난이도별 로컬 트랩 탈출

- 난이도는 키프레이즈 · 비키프레이즈 그룹 간 점수 간격 축소 ($\mu \downarrow$) · 점수 변동 증가 ($\sigma_\theta \uparrow$) · 라벨 결측 증가 ($\alpha \uparrow$) 로 조절
- 세 봉우리 (S/W/N) 가 겹칠수록 모드 간 식별이 어려워지는 시나리오

Easy $\mu=2.5, \sigma_\theta=0.35, \alpha=0.2$		
샘플러	Spear $\uparrow$	MSE _{cal} $\downarrow$
SGLD	0.698	1.612
qSGLD	0.732	0.988
cycSGLD	0.735	0.643
AWSGLD	0.740	0.377


Moderate $\mu=2.0, \sigma_\theta=0.5, \alpha=0.35$		
샘플러	Spear $\uparrow$	MSE _{cal} $\downarrow$
SGLD	0.663	1.320
qSGLD	0.728	0.939
cycSGLD	0.664	1.075
AWSGLD	0.757	0.439

Difficult $\mu=1.5, \sigma_\theta=0.6, \alpha=0.5$		
샘플러	Spear $\uparrow$	MSE _{cal} $\downarrow$
SGLD	0.093	1.308
qSGLD	0.327	1.153
cycSGLD	-0.556	0.938
AWSGLD	0.553	0.870

Sparse $\mu=2.0, \sigma_\theta=0.55, \alpha=0.4$		
샘플러	Spear $\uparrow$	MSE _{cal} $\downarrow$
SGLD	-0.064	1.476
qSGLD	0.466	1.014
cycSGLD	-0.537	0.745
AWSGLD	0.606	0.628

Study 1B - 로컬 트랩 진단

AWSGLD $\hat{R}$ 1.15 Cost/ESS 0.12	acMH $\hat{R}$ 1.78 Cost/ESS 22.77
SGLD $\hat{R}$ 10.21 Cost/ESS 0.42	cycSGLD $\hat{R}$ 5.09 Cost/ESS 0.51



카드 · 그림 설명: (1A) 난이도가 오를수록 trap 이 강해지며, SGLD·cycSGLD 는 Difficult·Sparse 에서 Spearman 이 음수로 붕괴하나 AWSGLD 는 전 난이도 1 위.

(1B) 그림 (좌) 은 다봉 trap 의 목표 사후 에너지 지형. 이 trap 에서 AWSGLD 만 수렴 ($\hat{R}$ 1.15) · 효율 (Cost/ESS 0.12, acMH 대비 약 190×) 을 동시 달성.

6 Study 2 · 표본 확장성 (빅데이터)

- 미니배치 비율을 고정하고 n 을 200→1500→10000 으로 확장해 대규모에서의

$n=10000$	Spearman $\uparrow$	$\hat{R}$ max $\downarrow$	Cost/ESS $\downarrow$
SGLD	0.215	7.52	469.5
qSGLD	0.748	2.11	348.4
cycSGLD	0.754	1.09	81.0
AWSGLD	0.757	1.09	56.9

표 3. AWSGLD 의 수렴 ($\hat{R}$) · 효율 (Cost/ESS) 순위는 n 이 커질수록 확대된다 ($n = 200/1500/10000$).

7 Study 3 · 수렴 진단

- 4-패널 진단 ($n=800, T=5000, \text{burn-in}=1000$):** 대표 성분 trace · $\|\theta_k - \bar{\theta}\|_2$ 변동 · 에너지 $U(x_k)$ · 누적 MSE.
- 에너지 trace 는 burn-in 내 고에너지 다봉 영역을 탐색한 뒤 단일 저에너지 영역으로 안정화되어 탐색과 수렴이 양립하며, 누적 MSE 는 정체 · 발산 없이 단조 수렴.
- Easy(에너지 800→480)·Difficult(850→465) 모두 동일 패턴으로 난이도에

핵심 결론

- 트랩 탈출 (Study 1A/1B):** 난이도가 올라 trap 이 강해져도 AWSGLD 만 순위 성능과 수렴 ($\hat{R}$ 1.15) · 효율 (acMH 대비 약 190×) 을 동시에 유지.
- 확장성 (Study 2):** $n=10^4$ 까지 수렴 · 효율 순위 일관 유지.
- 수렴 진단 (Study 3):** 에너지 · 누적 MSE trace 가 정체 없이 안정화. 수렴 진단 병행 다측 평가가 필수임을 확인.

향후 연구. 실데이터 (Hulth/Inspec) 평가