

SGMCMC를 활용한 LDA 추정 연구

I. 연구 목적

비지도 학습 분야에서 LDA(Latent Dirichlet Allocation)는 문서 내에 숨겨진 주제들을 찾아내는 대표적인 확률적 토픽 모델로 문서 집합에 대한 확률적 생성 모형이라고도 불린다. LDA는 각 문서의 주제는 단어 분포를 바탕으로 표현된다는 가정 하에 문서 집합 전체에 대한 잠재 구조를 추론한다. 때문에 LDA 모형을 통해 각 문서가 속할 토픽은 무엇이며 각 토픽에 영향을 주는 단어는 무엇인지 파악이 가능하다. 이러한 특성을 활용해 LDA는 문서 분류, 정보 검색, 추천 시스템, 사회 연결망 분석 등 다양한 실제 문제에 적용되어 왔다. 하지만 LDA 모형은 사후분포의 결합분포를 계산하는 것에 어려움이 있어 일반적으로 변형 모형을 통한 근사추론을 이용한다. 여기서 사용하는 MCMC(Markov Chain Monte Carlo)는 수렴 속도가 느리고, 높은 계산 비용이 필요하다. 이 문제점을 개선하기 위해, 본 연구에서는 계산 비용이 저렴하고 빅데이터에서도 속도가 빠른 SGMCMC(Stochastic Gradient Markov Chain Monte Carlo) 적용을 목표로 한다.

본 연구는 SGLD(Stochastic Gradient Langevin Dynamics) 기반의 추론 기법을 LDA에 적용하면서 기존의 MCMC 기반의 LDA가 지녔던 연산 속도와 샘플링 효율성, 확률적 추론의 정확도 면에서 실질적인 개선을 목표로 하고있다. 또한, SGLD-LDA 모델이 기존 LDA 모델에 비해 제공하는 이점 20Newsgroups 데이터에 적용하면서 다양한 성능 지표를 통해 검증하고자 한다. 그리고 검증된 SGMCMC-LDA를 통해 최근 인공지능 연구의 화두인 생성형 AI와 추론형 AI의 연구 추세를 비교해본다.

II. 연구 내용

본 연구는 대규모 텍스트 데이터 내에 숨겨진 주제를 효과적으로 추론하기 위해 확률적 토픽 모델인 LDA와 확장형 샘플링 알고리즘인 SGMCMC를 결합한 방법을 제안한다. SGMCMC 중 SGLD를 활용하여 기존 LDA의 추론 효율성과 한계를 극복하고자 한다.

LDA 사후 분포는 다음과 같이 정의된다.

$$p(z, \theta, \phi | w, \alpha, \beta) = \frac{p(\theta, z, w, \phi | \alpha, \beta)}{p(w | \alpha, \beta)}$$

여기서 θ 와 토픽별 단어 분포, z_n 와 w_n 은 각각 단어 위치 n 의 토픽 할당 변수와 관측된 단어이다. α 는 디리클레 분포(Dirichlet distribution)에서 생성된 파라미터이며 β 는 각 토픽의 단어 분포를 의미한다. 여기서 분포 $p(w | \alpha, \beta)$ 는 정규화 상수로서 모든 가능한 θ 와 z 에 대해 적분 또는 합산한 값을 의미한다. 따라서 분자인 결합확률 분포를 살펴보면 다음과 같다.

$$p(W, Z, \theta, \phi | \alpha, \beta) = \prod_{d=1}^M p(\theta_d | \alpha) \prod_{k=1}^K p(\phi_k | \beta) \prod_{d=1}^M \prod_{i=1}^{N_d} p(z_{di} | \theta_d) p(w_{di} | \phi_{z_{di}})$$

여기서 θ_d 와 ϕ_k 는 각 문서별 토픽 분포와 토픽별 단어 분포, $z_{d,n}$ 은 각 단어의 잠재 토픽 할당을 의미한다. 즉, α 를 통해 생성된 디리클레 분포(Dirichlet distribution)에서 토픽 분포인 θ_d 를 구하고 획득한 토픽 분포 θ_d 에서 토픽 z_n 을 구한다. 단어 w_n 이 토픽 z_n 에서 생성될 확률을 결합한 것이다.

LDA의 목적은 위 결합분포로부터 각 변수의 사후분포를 효과적으로 추정하는 것이지만, 이 과정은 일반적으로 고차원 데이터 및 복잡한 결합분포로 인해 계산량이 크고 전통적인 MCMC 방법으로는 수렴 속도 및 높은 계산 비용으로 인한 한계가 존재한다.

이에 본 연구는 전체 데이터 셋이 아닌 미니배치 (mini-batch)로 선택한 데이터에서 확률적 경사를 계산하고 SGMCMC를 반복적으로 적용한다. SGMCMC는 SGD(Stochastic Gradient Descent)에 Langevin 노이즈를 더해 확률적 샘플링을 가능하게 한다. 그리고 서브샘플링을 통해 에너지함수를 계산하여 속도는 빠르고 정확도는 높은 결과를 얻을 수 있다.

SGMCMC 중 가장 일반적인 알고리즘은 SGLD이다. SGLD는 베이지안 추론에서 $\pi(\psi | y) \propto \exp(-U(\psi))$ 인 목표 분포를 가정한다. 여기서 $U(\psi) = \sum_{i=1}^N U_i(\psi)$, $U_i(\psi) = -\log(y_i | \psi) - (1/N) \log \pi(\psi)$ 이다. 그리고 에너지함수 $U(\psi)$ 의 기울기를 분할하고 데이터 y 의 전체 데이터(N)가 아닌 일부(n)를 무작위로 추출(S_n)하여 간단하게 비편향 추정치를 얻는다.

이것은 $U(\psi)$ 의 기울기의 단순 추정치 $\widehat{\nabla} U(\psi)^{(n)} = \frac{N}{n} \sum_{i \in S_n} \nabla U_i(\psi)$ 이다.

이를 LDA 사후분포에 적용하여 ϕ 에 대한 추정치를 얻을 수 있다. 먼저, $U(\phi) = -\log(\pi(\phi))$ 로 목표 분포를 가정한다. 토픽 k 의 ϕ_k 에 대한 사후분포 $p(\phi_k | w_k, \beta)$ 는 가능도와 사전분포의 곱에 비례한다. 이를 합치면 $P(\phi_k | w_k, \beta) \propto \prod_{v=1}^V \phi_{k,v}^{N_{k,v}} \prod_{v=1}^V \phi_{k,v}^{\beta-1}$ 이고 음의 로그를 취해 에너지 분포를 구하면

$$U(\phi_k) = -\left(\sum_{v=1}^V (N_{k,v} + \beta - 1) \log \phi_{k,v}\right) \text{이다. 이 함수의 기울기를 분할하면 } \frac{\partial U(\phi_k)}{\partial \phi_{k,v}} = -\frac{N_{k,v} + \beta - 1}{\phi_{k,v}} \text{ 이}$$

$$\text{며, 단순 추정치는 } \widehat{\nabla_{\phi_{k,v}} U(\phi_k)} = -\frac{N \cdot N_{k,v}^{(B)}}{n \cdot \phi_{k,v}} - \frac{\beta - 1}{\phi_{k,v}} \text{이다.}$$

LDA에 SGLD를 적용한다면 빠르지만 정확도 높은 토픽 모델링이 가능하다.

SGLD-Gibbs-LDA 알고리즘:

a. 초기치 입력: $\psi_0, \{h_0, \dots, h_K\}$

b. (ψ 업데이트) $k = 1, \dots, K$ 반복

(b.1) (비복원 추출) 데이터 표본공간에서 데이터 y 의 일부(n)를 비복원 추출한다.

$$(S_n \subset 1, \dots, N)$$

$$(b.2) (U(\psi) 기울기 추정) \widehat{\nabla} U(\psi)^{(n)} = \frac{N}{n} \sum_{i \in S_n} \nabla U_i(\psi)$$

$$(b.3) (\xi_k \text{ 생성}) \xi_k \sim \mathcal{N}(0, h_k I)$$

$$(b.4) \psi_{k+1} = \psi_k - \frac{h_k}{2} \widehat{\nabla} U(\psi_k)^{(n)} + \xi_k$$

이때 h_k 는 학습률(step size), ξ_k 는 가우시안 노이즈를 의미한다.

SGLD-Gibbs-LDA 알고리즘:

a. 초기치 입력:

데이터: 문서 집합 $D = d_1, \dots, d_D$

초기 파라미터: $\phi^{(0)}, \theta^{(0)}, z^{(0)}$

b. 반복 수행

(b.1) 미니배치 샘플링:

문서 집합 D 에서 크기 B 인 미니배치 S_k 를 무작위로 추출: $S_k \subseteq \{1, \dots, D\}$

(b.2) Gibbs 샘플링 (z, θ 업데이트)

각 단어 w_{d_i} 에 대해 다음의 조건부 분포에 따라 새로운 토픽 z_{d_i} 를

샘플링한다. $P(z_{d_i} = t | \cdot) \propto \left(\frac{n_{dt}^{(-i)} + \alpha}{\sum_t n_{dt}^{(-i)} + \text{Alpha}} \right) \cdot \phi_{tw_d}$ 여기서 $n_{dt}^{(-i)}$ 는 현재 단어 제외 문서 d 내 토픽

t 의 카운트이다.

이후 θ_d 는 갱신: $\theta_{d,t} = \frac{n_{dt} + \alpha}{n_d + T\alpha}$ (*Dirichlet posterior*의 기대값)

(b.3) 각 토픽에 대한 기울기 계산: $\nabla_{\phi_{k,v}} \widehat{U(\phi_k)} = -\frac{N \cdot N_{kv}^{(B)}}{n \cdot \phi_{k,v}} - \frac{\beta - 1}{\phi_{k,v}}$

(b.4) (ξ_k 생성) $\xi_k \sim \mathcal{N}(0, h_k I)$

(b.5) SGLD 업데이트: $\phi_t^{(k+1)} = \phi_t^{(k)} + \frac{h_k}{2} \widehat{\nabla} \phi_t U(\phi_t) + \xi_k$

이때 h_k 는 학습률(step size), ξ_k 는 가우시안 노이즈를 의미한다.

실험은 20 Newsgroups 및 Scopus 논문 데이터셋을 대상으로 하며 전처리(불용어 제거, 토큰화 등)와 하이퍼파라미터(T, α, β , 반복횟수 등) 설정, 기존 LDA/Gibbs Sampling 적용, /SGLD+Gibbs 사용 LDA를 비교한다. 각 실험은 Perplexity, Topic Coherence, Silhouette 등 표준 평가지표로 성능을 측정한다.

III. 연구 결과

SGLD 기반 LDA(Minibatch SGLD-LDA)와 기존 LDA의 실험 결과를 다양한 평가지표와 함께 정량적·정성적으로 비교·분석한다. 특히, Perplexity, Topic Coherence, Silhouette Score를 중심으로 파라미터 조정(learning rate, batch size 등)에 따른 결과 변화를 상세히 논의하고, 모델별 강점과 한계, 실제 적용 가능성을 해석하였다.

실험은 20 Newsgroups 데이터셋 전체 문서(약 18,000여 개)를 사용하였고, 전처리는 불용어 제거, n-gram 확장, 빈도 기준 필터링 등으로 일관되게 수행하였다. SGLD-LDA는 batch size, learning rate, 반복 횟수 등 하이퍼파라미터를 다양하게 실험하였으며, 표준 LDA 패키지(gensim, sklearn 등)도 동일 데이터 및 전처리로 비교 평가하였다.

본 연구에서는 SGLD-LDA의 성능 평가를 위해 동일한 데이터셋(20 Newsgroups)과 동일한 전처리 및 실험 조건 하에서 전통적인 LDA와 Gibbs Sampling 기반 LDA와의 결과도 함께 비교 분석하였다. LDA는 완전한 결합분포에서의 반복적 표본 추출을 통해 토픽-단어 분포와 문서-토픽 분포를 추정하는 고전적 방식으로 통계적 신뢰도와 생성 품질(Perplexity) 면에서 기준점이 되는 방법이다.

반면, SGLD-LDA는 미니배치와 확률적 경사하강법, 노이즈 주입을 결합한 근사 추론 방법으로

효율성과 확장성, 계산 속도를 개선하는 것을 주목적으로 한다.

실험에서는 세 방법 모두 토픽 수(T)를 변화시켜 Perplexity (생성 품질), Coherence (주제 해석력), Silhouette (토픽-문서 클러스터링 명확성) 지표를 동일하게 측정하였다.

Model	T	Perplexity	Coherence	Silhouette
LDA (패키지)	3	4602.22	0.431	0.815
	4	4538.40	0.444	0.763
	5	4733.56	0.421	0.728
	10	5179.70	0.437	0.661
	15	5392.35	0.450	0.654
	20	5483.93	0.437	0.644
Gibbs	3	2105.5	0.591	0.697
	4	2010.3	0.538	0.616
	5	1914.6	0.524	0.587
	10	1760.3	0.488	0.428
	15	1570.1	0.477	0.407
	20	1513.2	0.409	0.357
SGLD+Gibbs	3	3612.4	0.572	0.687
	4	3293.3	0.583	0.651
	5	3126.5	0.705	0.622
	10	3615.7	0.622	0.581
	15	7357.0	0.652	0.630
	20	7962.2	0.603	0.619

Table 1. 토픽 수에 따른 각 모델의 지표

토픽 모델링에서 토픽 수(T)는 분석 결과의 품질과 해석 가능성을 크게 좌우하는 핵심 하이퍼파라미터이다. 따라서 Table 1.은 모든 실험은 토픽 수(T)를 3, 4, 5, 10, 15, 20으로 변화시키면서, Perplexity, Coherence, Silhouette Score의 변화를 집중적으로 관찰하였다.




Figure 1. 토픽 수에 따른 SGLD의 지표

세 지표를 모두 고려한 결과, Perplexity와 Coherence, Silhouette Score가 동시에 양호한 균형점이 T=5~10 구간에 위치함을 관찰하였다. 특히, Coherence가 급격히 상승하거나 최대치를 보이는 T에서 Perplexity가 급증하지 않고, Silhouette Score도 크게 저하되지 않는 구간을 최적 토픽 수로 선정하였다. 결론적으로, 본 연구에서는 Coherence 점수가 가장 높은 T를 1차 기준으로 선정하였으며, Perplexity 및 Silhouette Score가 실용적으로 수용 가능한 수준임을 추가로 확인한 뒤 최종적으로 T=5~9 사이에서 적정 토픽 수를 결정하였다.

Perplexity는 모델이 문서 집합을 얼마나 잘 생성할 수 있는지 나타내는 지표로, 값이 낮을수록 더 우수한 생성 품질을 의미한다. 결과를 보면 Gibbs Sampling을 이용한 LDA 모델이 전 구간에서 가장 낮은 Perplexity를 보이며 생성 품질 면에서 우수함을 확인할 수 있다. SGLD를 사용한 모델은 그에 비해 낮은 성능을 보이지만 이는 SGLD 기반의 확률적 근사 추론이 토픽수가 커질수록 분포 추정의 어려움과 노이즈의 영향을 받기 때문으로 해석된다.

Silhouette 점수는 문서-토픽 클러스터링의 명확성을 측정하는 지표로, 값이 낮을수록 각 문서가 특정 토픽에 뚜렷하게 소속되어 있음을 확인할 수 있다. 기본 LDA 패키지가 대부분의 T에서 Silhouette 0.7 이상으로 높은 수치를 보였다. 반면, Gibbs Sampling과 SGLD+Gibbs는 T가 커질수록 Silhouette가 낮아지는 경향을 보이며, 이것은 확률적 샘플링 기반의 두 방법이 토픽 수가 많아질수록 문서의 토픽 분포가 분산되기 때문으로 해석된다.

Coherence는 토픽 안의 상위 단어들이 실제로 의미적으로 잘 어울리는지 평가하며, 값이 높을수록 해당 토픽이 해석 가능한 주제로 잘 구성되었음을 의미한다. SGLD+Gibbs는 T=515 구간에서 0.7050.652의 가장 높은 Coherence를 보였으며 특히 T=5에서 표준 LDA(0.464), Gibbs(0.524)보다 확연히 높은 수치를 기록했다. Gibbs Sampling 역시 일관되게 LDA 패키지보다 높은 Coherence를 유지했다. 이러한 결과는 SGLD의 확률적 샘플링 및 미니배치 기반 근사 추론이 각 토픽의 의미적 일관성과 실제 해석 가능성에서 탁월한 효과를 발휘함을 보여준다.

종합적으로, SGLD+Gibbs는 적정 토픽 수(T=4~6) 구간에서 Perplexity와 Silhouette Score 모두 실용적으로 무리가 없는 수준을 유지하면서도, 동시에 최고 수준의 Coherence를 달성하는 균형 잡힌 성능을 보였다. 이러한 균형은 SGLD 기반의 확률적 샘플링이 모델의 과도한 과적합을 방지하면서도 실제 데이터의 구조적 특성을 효과적으로 반영함을 시사한다. 실제 적용을 고려할 때, 단순한 수치적 생성력보다는 실질적 해석력을 의미하는 Coherence가 더 큰 가치를 지니는 경우가 많다는 점에서 SGLD+Gibbs는 매우 실용적인 선택지로 부각된다. 특히 인문학이나 사회과학 연구에서 토픽의 의미적 해석이 중요한 응용 분야에서 SGLD+Gibbs의 우수성이 두드러질 것으로 보인다. 더 나아가 SGLD+Gibbs는 미니배치와 확률적 경사 기반 샘플링, 노이즈 주입 등 최신 베이지안 추론 기법을 접목함으로써 대규모 데이터셋이나 연산 자원이 제한된 환경에서도 효율성과 확장성이 뛰어나다는 실용적 강점을 가진다. 이는 대용량 실시간 토픽 분석, 클라우드 기반 분산처리 등 현대적인 응용 분야에서 전통적 LDA 방식보다 더 현실적인 선택지가 될 수 있음을 의미한다.

IV. 참고 문헌

- Ding, N., Fang, Y., Babbush, R., Chen, C., Skeel, R. D., & Neven, H. (2014). Stochastic Gradient MCMC for Bayesian inference. *Proceedings of the 31st International Conference on Machine Learning*, 32, 1686-1694.
- Patterson, S., & Teh, Y. W. (2013). Stochastic gradient Riemannian Langevin dynamics on the probability simplex. *Advances in Neural Information Processing Systems*, 26, 3102-3110.
- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993-1022. <https://jmlr.org/papers/v3/blei03a.html>
- Blei, D. M., & Lafferty, J. D. (2007). A correlated topic model of Science. *Annals of Applied Statistics*, 1(1), 17-35. <https://doi.org/10.1214/07-AOAS114>
- Blei, D. M., Griffiths, T. L., Jordan, M. I., & Tenenbaum, J. B. (2004). Hierarchical topic models and the nested Chinese restaurant process. In *Advances in Neural Information Processing Systems* (Vol. 16). <https://papers.nips.cc/paper/2003/file/ea7a41e4be7f41c9e1d0d65ccf1bc1-Paper.pdf>
- Griffiths, T. L., & Steyvers, M. (2004). Finding scientific topics. *Proceedings of the National Academy of Sciences*, 101(Suppl 1), 5228-5235. <https://doi.org/10.1073/pnas.0307752101>
- Teh, Y. W., Jordan, M. I., Beal, M. J., & Blei, D. M. (2006). Hierarchical Dirichlet Processes. *Journal of the American Statistical Association*, 101(476), 1566-1581. <https://doi.org/10.1198/016214506000000302>
- Blei, D. M., & Lafferty, J. D. (2009). Topic Models. In A. Srivastava & M. Sahami (Eds.), *Text Mining: Classification, Clustering, and Applications* (pp. 71-94). CRC Press.
- Welling, M., & Teh, Y. W. (2011). Bayesian learning via stochastic gradient Langevin dynamics. In *Proceedings of the 28th International Conference on Machine Learning (ICML)* (pp. 681-688). https://icml.cc/2011/papers/398_icmlpaper.pdf
- Ding, N., Fang, Y., Babbush, R., Chen, C., Skeel, R. D., & Neven, H. (2014). Bayesian sampling using stochastic gradient thermostats. In *Advances in Neural Information Processing Systems* (pp. 3203-3211). <https://proceedings.neurips.cc/paper/2014/file/eddb1e65e01a0a6b8180bfb15d174f0c-Paper.pdf>
- Patterson, S., & Teh, Y. W. (2013). Stochastic gradient Riemannian Langevin dynamics on the probability simplex. In *Advances in Neural Information Processing Systems* (pp. 3102-3110). <https://proceedings.neurips.cc/paper/2013/file/f95a5c0e0f2a6b0b3d1060c253c4b6b1-Paper.pdf>
- Chen, T., Fox, E., & Guestrin, C. (2014). Stochastic gradient Hamiltonian Monte Carlo. In *Proceedings of the 31st International Conference on Machine Learning (ICML)* (pp. 1683-1691). <https://proceedings.mlr.press/v32/cheni14.html>
- Ma, Y.-A., Chen, T., & Fox, E. (2015). A complete recipe for stochastic gradient

MCMC. In *Advances in Neural Information Processing Systems* (pp. 2917–2925).
<https://proceedings.neurips.cc/paper/2015/file/2963c1f8b71973e00aade6c7c3fdf4a0-Paper.pdf>

Li, C., Chen, C., Carlson, D., & Carin, L. (2016). Preconditioned stochastic gradient Langevin dynamics for deep neural networks. In *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence* (pp. 1788–1794).
<https://www.aaai.org/ocs/index.php/AAAI/AAAI16/paper/view/12285>

Griffiths, T. L., & Steyvers, M. (2004). Finding scientific topics. *Proceedings of the National Academy of Sciences*, 101(Suppl 1), 5228–5235.
<https://doi.org/10.1073/pnas.0307752101>

Heinrich, G. (2005). Parameter estimation for text analysis. Technical Report.
<https://www.arbylon.net/publications/text-est.pdf>

Yao, L., Mimno, D., & McCallum, A. (2009). Efficient methods for topic model inference on streaming document collections. In *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 937–946).
<https://doi.org/10.1145/1557019.1557125>

Asuncion, A., Welling, M., Smyth, P., & Teh, Y. W. (2009). On smoothing and inference for topic models. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)* (pp. 27–34).
https://auai.org/uai2009/papers/UAI2009_0056.pdf

Porteous, I., Newman, D., Ihler, A., Asuncion, A., Smyth, P., & Welling, M. (2008). Fast collapsed Gibbs sampling for latent Dirichlet allocation. In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 569–577). <https://doi.org/10.1145/1401890.1401959>

Wallach, H. M., Mimno, D., & McCallum, A. (2009). Rethinking LDA: Why priors matter. In *Advances in Neural Information Processing Systems* (pp. 1973–1981).
<https://proceedings.neurips.cc/paper/2009/file/385915efab2b4735b1de5c2a5b7f2a2e-Paper.pdf>
