

RAG와 LLM을 활용한 금융 심사 설명력 향상 방안*

홍지윤¹, 주아림², 전수영³

요 약

최근 대규모 언어모델(LLM)의 발전으로 자연어 처리 기반 시스템의 활용 가능성이 크게 확장되고 있다. 특히 금융 도메인에서는 고객 맞춤형 피드백을 통한 설명 가능성과 신뢰성이 중요한 요소로 부상하고 있다. 그러나 기존의 규칙 기반 금융대출심사 시스템은 개인의 구체적 재무 상황과 맥락을 충분히 반영하지 못하고 정형화된 피드백만을 제공하여 고객의 행동 변화를 유도하는 데 한계가 있다. 본 연구는 이러한 문제점을 해결하기 위해 RAG(retrieval augmented generation)를 결합한 LLM 기반 금융대출심사 시스템을 제안한다. 제안된 시스템은 외부 금융 문서를 RAG로 검색한 뒤 검색된 컨텍스트가 LLM에 입력으로 들어가는 구조로 구현되었다. 이는 금융 문서 및 고객 데이터를 기반으로 실시간으로 외부 지식을 검색하여 전문적인 문서 기반의 구체적이고 실행 가능한 금융 개선 방안을 제공한다. 실제 고객 데이터를 활용한 실험 결과, 제안된 RAG 기반 시스템은 기존 시스템 대비 정보 검색 및 자연어 생성 성능 측면에서 의미 있는 성능 향상을 보였으며, 전문적인 금융 문서 참조를 통해 개인 맞춤형 금융 서비스의 신뢰성과 효율성을 높이는 데 기여할 수 있음을 보여준다.

주요 용어: RAG, LLM, 금융심사, 정보검색, 자연어생성.

1. 서론

최근 대규모 언어 모델(large language models, LLM)의 발전은 강력한 사전 학습된 방대한 지식 기반을 바탕으로 다양한 영역에서의 활용 가능성을 보여주고 있다(No et al., 2024). 예를 들어, Fin-BERT 모델 기반 감성 점수 활용 주가 예측 연구(Kim, Kang, Choi, 2025)와 열차 안전 의제의 방향성을 제시하는 연구(Lee et al., 2024b)가 있다. LLM은 기존의 규칙 기반 시스템과 달리, 문맥에 기반한 유연한 응답 생성이 가능하며, 다양한 금융 문서와 데이터를 기반으로 한 맞춤형 설명을 제공할 수 있다는 점에서 주목받고 있다.

하지만 모델이 학습한 시점 이후의 정보를 포함하지 못하며 구체적인 사실 기반 응답이 필요한 영역에서는 오류가 발생할 수 있다. RAG(retrieval augmented generation)는 이러한 한계를 보완할 수 있는 기술로 질문에 답변할 때 외부 문서에서 관련 정보를 검색하고, 이를 바탕으로 텍스트를 생

*이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2024-00352792).

¹30019 세종시 세종로 2511, 고려대학교 빅데이터사이언스학부 학사과정. E-mail: julie2302@korea.ac.kr

²30019 세종시 세종로 2511, 고려대학교 경제통계학과 박사수료. E-mail: joalim@korea.ac.kr

³(교신저자) 30019 세종시 세종로 2511, 고려대학교 빅데이터사이언스학부 교수. E-mail: scheon@korea.ac.kr

[접수 2025년 3월 31일; 수정 2025년 4월 15일; 게재 확정 2025년 4월 18일]

성하는 방식이다. LLM이 외부 문서를 실시간으로 검색하고 참조할 수 있도록 하여, 보다 신뢰도 높고 설명력 있는 응답 생성이 가능하게 해 환각 문제를 줄이고 최신 정보를 반영할 수 있다. 이러한 부분은 특히 금융·법률·의료 등과 같은 고위험 도메인에서도 실용성과 신뢰도를 동시에 확보 가능한 의미 있는 진전을 보여줄 수 있다. Lee et al.(2024a)은 최종 결과 작성에서 자연어처리 기술이 많은 부분을 해결해 주었지만, 전문가의 지식과 판단이 중요한 역할을 하였다고 설명하며 여전히 도메인 특화 영역에서 인간 전문가의 개입이 필요함을 강조하였다.

본 연구는 이러한 한계를 RAG 구조를 통해 완화하고자 한다. 외부 문서 기반 지식을 결합한 RAG는 설명력 있는 금융 응답 생성이라는 측면에서 특히 유용하며 이는 기존의 LLM 기반 시스템과의 차별점으로 작용한다. 국내에서는 이미 신한투자증권과 KB국민카드 등에서 RAG 기술을 적용하여 내부 문서 검색, 고객 상담 효율화 등에 성과를 보이고 있지만(AI Times, 2024; Business Post, 2024), 개인의 금융 상태를 분석하고 맞춤형 개선 전략을 제시하는 피드백 시스템은 본격적으로 도입되지 않았다. 전통적인 신용평가는 고객의 FICO 점수, DTI(debt-to-income) 비율, 연체 이력 등의 정량 지표를 기반으로 심사 결과를 도출한다는 한계를 안고 있다. 특히 신용대출 분야에서 대출 심사 결과는 고객의 금융 접근성을 좌우하는 중요한 요소임에도 불구하고 기존 시스템은 “신용점수가 낮습니다”, “DTI가 높습니다” 등 기계적 문구만을 제공하며 고객이 실제로 행동할 수 있는 전략을 제시하는 것이 어렵다.

이에 본 연구는 RAG 구조를 적용한 LLM 시스템을 설계하여 고객의 대출 심사 결과를 설명하고 대출 거절 사유에 대한 설명과 함께 문서 기반의 실질적인 개선 방안을 제공하는 사용자 중심 피드백 시스템을 제안한다. 신용평가 매뉴얼, 금융상품 설명서, 금융 QA 데이터셋 등 금융 도메인 문서들과 실제 고객 데이터를 통합하여 설명력 있고 신뢰성 있는 금융 피드백 제공이 가능한 구조를 구축하고자 한다. 이를 통해 단순한 결과 통지를 넘어 고객의 금융 이해도 향상과 실질적인 신용 개선 행동을 유도하는 새로운 인공지능 기반 신용평가 도구로서의 가능성을 제시한다. 추가적으로 클라우드 기반 LLM은 최신 모델과 기능에 신속하게 접근할 수 있고 관리가 간편하다는 장점이 있지만, 동시에 심각한 보안 리스크를 내포하고 있다. 특히 외부 서버로 데이터를 전송함에 따라 개인정보 및 민감한 정보 유출의 위험성이 높아진다(Park, Lee, 2022). 금융, 의료와 같은 고보안 도메인에서 클라우드 기반 LLM 사용은 규정 위반 가능성이 크기 때문에 전략적 선택에 있어 매우 신중한 접근이 필요하다. 데이터 외부 전송에 따른 잠재적 보안 취약성은 기업의 정보보호 정책과 직접적으로 상충될 수 있다(Kim, Lee, Kang, 2023). 본 연구에서는 내부망에서만 동작하기 때문에 데이터 유출 위험이 낮은 Self-hosted LLM(SHLLM)을 사용한다. SHLLM은 프롬프트와 응답을 완전히 로컬에서 처리할 수 있어(Park, Lee, 2022) 보안성 면에서도 훌륭하다.

2장에서 기본 시스템 흐름, 3장에서는 RAG와 추가 시스템에 대한 설명, 4장에서 데이터와 그에 대한 분석 결과와 5장에서는 향후 연구에 대해 서술한다.

2. 기본 시스템(baseline system) 프로세스

대출 시스템은 정형화된 데이터와 사전에 정의된 규칙 기반 구조로 설계되어 있다. 이러한 시스템은 고객의 신용정보와 금융 데이터를 수집하고, 이를 바탕으로 대출 승인 여부를 결정한다(Kim, Lee, 2022). 기본 시스템(baseline system) 프로세스에 사용되는 LLM은 LG AI 연구원에서 2023년도

에 개발한 EXAONE-Deep-7.8B 모델로 SHLLM 중 하나이며 한국어 성능에서 우수한 성과를 보인다. 기본 시스템 프로세스는 다음과 같다(Figure 1).

- (1) 데이터 로드: 고객의 개인정보와 재무 데이터를 수집하고, 동시에 은행의 금융상품 관련 크롤링 데이터를 불러온다. 수집되는 데이터에는 재직 기간, 연령대, 연소득, 부채 수준, 연체 이력 등 고객의 재무 상태와 관련된 다양한 정보를 포함한다.
- (2) 대출 및 금융상품 분석: 수집된 고객 데이터를 기반으로 대출 승인 여부를 판단하며, 동시에 금융상품 데이터를 '금융상품명', '상품종류', '가입대상', '상품설명'으로 구조화한다. 이 과정에서 고객 정보에서 대출 상태를 확인하고 재정 상태를 확인한다.
- (3) 금융상품 추천 및 피드백: 고객의 정보 및 재정 상태에 따라 각 조건을 만족할 때 변수 간의 중요도를 고려한 가중치를 부여하는 방식(Park, Ahn, Choi, 2025)으로 금융상품에 대한 적합도를 계산한다. 또한, 고객 정보와 금융상품 데이터를 각각 임베딩하여 두 벡터의 코사인 유사도를 적합도로 사용하였다. 계산된 두 적합도의 평균 중 상위 3개를 추출해 상품 요약 정보와 추천 이유, 주요 혜택과 유의사항을 포함한 응답을 제공한다.

대출에 문제가 있는 경우에는 사전 정의된 기준에 따라 DTI 비율, 신용점수 임계값 등을 계산하여 주요 거절 사유와 일반적인 개선 조언을 사전에 작성된 템플릿 메시지를 통해 고객에게 전달한다. 이때의 조언들은 모든 고객들에게 동일하게 적용되는 사전 매핑 규칙 기반 문장 형태이다.

이러한 시스템은 여러 가지 구조적 한계를 가지고 있다. 첫째, 모든 고객에게 동일한 형식의 문장이 반복되며 출력되어 개인의 구체적인 상황을 충분하게 반영하지 못한다. 예를 들어, “DTI 비율이 높습니다”와 같은 피드백은 고객이 어떤 부채를 우선적으로 상환해야 하는지 등 구체적인 맥락이 부족하다. 둘째, 신용평가사나 금융기관에서 사용하는 실제 심사 기준 및 평가 문서의 내용을 직접적으로 반영하지 않기 때문에 제한된 정보만으로 의사결정을 해야 한다. 또한, 기준이 변경되면 실시간으로 반영하기 어려워 결정과 설명의 정확성에 한계가 있다. 셋째, 표준화된 템플릿 메시지는 설득력과 신뢰도가 낮다는 인상을 줄 수 있다. 개인화된 분석과 맥락을 고려한 조언이 아닌, 일반적인 조언은 고객의 행동 변화를 유도하기 어려우며 제한적인 역할을 한다(Jeong, Hong, 2023).




Figure 1. Baseline system

이와 같은 기본 시스템의 한계점들은 신뢰성과 설명력을 요구하는 금융 도메인에서 고객 만족도를 향상시키고 잠재적 비즈니스 기회 제공에 장애물로 작용한다(Kang, Oho, Choi, 2022). 따라서 보다 개인화되고 설명력 있는 피드백의 필요성이 증가하고 있다.

3. RAG 기반 시스템 프로세스

기존의 규칙 기반 시스템이 가진 설명력 및 신뢰도의 한계와 고객 맞춤형 피드백 부족 문제를 보완하기 위해 본 연구에서는 RAG를 활용하여 보다 정교하고 설득력 있는 대출 심사 보조 시스템을 설계하였다.

3.1. RAG(retrieval augmented generation; Gao, et al., 2023)

RAG의 구조는 Figure 2와 같이 크게 검색모듈과 생성모듈로 이루어져 있다. 먼저, 사용자가 입력한 질문이나 질의가 주어지면, RAG의 검색모듈이 동작하여 FAISS(Facebook AI similarity search) 같은 벡터 스토어(vector store) 형태로 구축된 외부 지식 저장소에서 코사인 유사도를 통해 질문과 관련성이 높은 정보를 찾는다. 이때 벡터 스토어는 저장된 모든 정보나 문서는 미리 텍스트 임베딩 과정을 통해 벡터 형태로 변환된 상태로 관리된다. 검색 모듈에 의해 선택된 관련 문서나 정보는 이후 생성모듈로 전달된다. 생성모듈은 LLM으로 구성되며, 이는 검색모듈에서 추출한 컨텍스트와 원본 질문을 동시에 입력으로 받아 정확하고 맥락에 적합한 답변을 생성한다.

본 연구의 시스템은 LangChain의 RetrievalQA처럼 외부의 FAISS 기반 검색 모듈 RAG의 검색 결과를 생성 모델인 LLM에 입력으로 보내 문장을 생성하는 프로세스로 검색과 생성을 분리한 구조로 구현하였다. 이러한 구조를 통해 RAG 모델은 언어모델 자체에만 의존하는 방식과 달리, 외부에서 제공된 신뢰할 수 있고 최신성을 갖춘 정보를 실시간으로 활용할 수 있다. 결과적으로 RAG는 언어모델의 약점으로 지적되는 사실적 정확성 부족 문제를 크게 개선하며, 전문적이거나 최신성을 요구하는 응용 분야에서 높은 성능을 제공한다.




Figure 2. The structure of RAG system(Gao et al., 2023)

3.2. RAG 기반 시스템 프로세스

RAG 기반 시스템 프로세스는 데이터 로드, 대출 조회 및 데이터 처리, 거절 사유 분석, 상품 추천 순으로 다음과 같이 총 4 단계를 거쳐 진행된다(Figure 3).

(1) 데이터 로드

기본 시스템과 동일한 고객의 개인정보와 재무 데이터와 은행의 금융상품 관련 크롤링 데이터를 불러온다. 또한, RAG 시스템에 사용할 금융 RAG 데이터셋, 대출 관련 문서 등을 불러온다.

(2) 대출 조회 및 데이터 처리

대출 승인 여부 판단은 고객 데이터에 나와 있는 대출 승인 여부를 확인한다. PyMuPDF(fitz) 라이브러리를 활용하여 PDF 형식의 문서를 추출하고, RecursiveCharacterTextSplitter를 통해 최대한 의미 단위가 보존되도록 텍스트를 분할한 후 임베딩 처리한다. 이 과정에서 원문의 출처, 페이지 번호, 섹션 등 메타데이터를 보존하여 검색 결과의 추적성과 신뢰성을 확보한다. 텍스트 임베딩은 sentence-transformers 프레임워크의 all-MiniLM-L6-v2 모델(Reimers, Gurevych, 2019)을 사용하여 생성되며, 이는 384차원의 밀집 벡터 공간에서 의미적 유사도를 포착할 수 있다. 이를 벡터 저장소인 FAISS 기반 벡터 스토어에 저장한다. 또한, 새로운 문서가 시스템에 추가될 경우, 임베딩 후 기존 FAISS 인덱스에 병합되어 일관된 검색이 가능하도록 한다.

(3) 거절 사유 분석

고객의 대출 심사 과정에서 DTI 비율, 신용점수, 연체 이력 등 주요 평가 지표를 기반으로 RAG 기법을 활용한 언어 모델을 적용하였다. 언어모델은 기본 시스템과 동일한 EXAONE-Deep-7.8B-AWQ 모델을 사용하였다. 프롬프트는 “다음 고객은 대출 신청을 했으나 거절되었습니다. 아래 고객 정보를 참고하여 거절 사유를 상세히 설명해 주세요. 반드시 금융 문서를 기반으로 판단하고, 구체적인 수치와 기준이 있으면 함께 제시해 주세요.”와 같이 구성하여, 고객 정보와 신용평가 문서를 기반으로 한 심층적인 추론을 유도하였다.

LangChain 기반 RetrievalQA 파이프라인을 통해 벡터 검색 결과와 언어 모델을 연계하여 컨텍스트 인식 응답을 생성하도록 한다. 먼저 문서 벡터 스토어에서 관련 문서를 검색한 후, 검색된 문서의 내용을 참조하여 언어 모델이 자연어 응답을 생성하는 방식이다. 이를 통해 기존의 단순 규칙 기반 피드백 시스템에서 탈피하여, 문서 기반의 근거 있는 설명과 구체적인 실행 계획을 제공함으로써 고객의 이해도를 높이고 향후 행동 개선을 위한 실질적인 가이드라인을 제시할 수 있다.

(4) 상품 추천

기존 기본 시스템의 방법과 동일하게 적합도 점수로 판단하여 상위 3개의 상품을 추천한다. 더불어 응답 제공 시 사전 구축된 금융 관련 PDF 및 RAG-KO 데이터 기반 문서를 기반으로 고객에게 적합한 이유를 생성하여 LLM이 응답하도록 하였다. 이렇게 RAG를 사용한 시스템은 고객 데이터와 금융 도메인 데이터를 결합해 단순한 규칙 기반의 거절 사유 및 개선 방안 제시를 넘어 전문적인 문서의 근거하여 구체적인 개선 방안과 상품을 추천하는 종합적인 솔루션을 제공한다.




Figure 3. RAG based system process

4. 실증 자료 분석

4.1. RAG 시스템 평가 분석

본 연구에서는 기본 시스템과 RAG 기반으로 확장한 시스템과 비교 평가를 진행하였다. 두 시스템은 동일한 고객 데이터와 금융상품 데이터를 사용하고, 문서 기반 생성 여부와 질의응답 방식에 차이를 두었다. 두 시스템의 응답에 대해 금융 도메인 데이터들과 신용대출 메뉴얼, 대출 솔루션, 신용 평가 시스템 데이터를 기준에 두고 평가하였다. 기본 시스템은 정량 지표를 기준으로 거절 사유를 판단하고, 고정된 규칙에 따라 사전 정의된 문구를 LLM이 생성하고 출력하는 방식이다. RAG 기반 시스템은 정량 지표를 확인하고, 시스템은 거절 사유를 자연어 프롬프트로 변환하여 관련 문서를 벡터 기반으로 검색하고, 해당 문서를 바탕으로 LLM이 개선 방안을 제시한다.

성능 평가는 정보 검색과 자연어 생성 성능 두 측면에서 이뤄졌다. 정보 검색 평가 지표로 BM25(best matching 25) 점수와 코사인 유사도를 사용하였다. BM25는 정보 검색 분야에서 가장 널리 사용되는 랭킹 함수로, 질의어와 문서 간의 단어 기반 정합성을 측정한다(Robertson, Zaragoza, 2009). 코사인 유사도는 다차원 벡터 공간에서 두 벡터 간의 각도를 측정하여 의미적 유사도를 평가하는 방법이다(Reimers, Gurevych, 2019). 이 방법은 단순한 단어 일치율을 넘어 문맥적 의미를 고려한 유사도 측정이 가능하다. 최적의 정보 검색 시스템을 구축하기 위해서는 이 두 방법을 상황에 맞게 적절히 활용하는 것이 중요하다(Lee, Park, 2024).

자연어 생성 지표로는 ROUGE-1, ROUGE-2, BERTScore를 사용했다. ROUGE(recall oriented understudy for gisting evaluation)는 텍스트 요약 및 기계 번역 분야에서 널리 사용되는 평가 지표로, 생성된 텍스트와 참조 텍스트 간의 중복률을 측정한다(Ng, Petrov, 2022). ROUGE-1은 단일 단어 수준의 일치율(Ng, Petrov, 2022), ROUGE-L은 최장 공통부분 시퀀스를 기반으로 유사성을 분석한다(Zhang, Liu, 2022). BERTScore는 BERT 언어 모델의 문맥적 임베딩을 활용하여 텍스트 간 의미론적 유사도를 평가하는 방법이다(Dou, Xu, Wang, 2023). 단순한 단어 일치율을 넘어 문장의 의미적 맥락을 깊이 있게 분석할 수 있다.

Table 1. Results based on the number of RAG references

Evaluation Metric\Number of references	top_k=1	top_k=3	top_k=5
BM25	7.86	11.67	8.76
Cosine Similarity	0.6540	0.7415	0.6232
ROUGE-1	0.0488	0.1821	0.2513
ROUGE-L	0.0488	0.1655	0.2513
BERTScore	0.8341	0.8587	0.8390

본 연구는 대출이 거부된 고객 중 10명을 랜덤으로 뽑아 거절 사유와 개선 방안에 대한 응답을 평가한 결과의 평균을 사용했다. 먼저, RAG 시스템의 최적화를 위해 RAG에서 검색된 문서의 수 (top_k)를 조절하여 적절한 값을 설정하였다. top_k 값은 검색 성능과 생성 품질 간의 균형을 조절하는 핵심 하이퍼파라미터로, 너무 낮으면 핵심 정보를 놓칠 수 있고, 너무 높으면 관련 없는 정보가 포함되어 답변의 일관성과 정확성을 해칠 수 있다(Lewis et al., 2020). 본 연구에서 RAG에 사용되는 문서들이 동일한 주제를 반복하거나 유사한 제도 설명을 포함하고 있다. 그러므로 top_k 값을 증가시키더라도 참조 문서 간 의미 중복이 크므로 생성 응답의 다양성에는 큰 변화가 없을 수 있다(Lewis et al., 2020). Table 1은 top_k에 따라 RAG에 의해 선택된 문서 벡터와 질의 벡터를 이용하여 구한 결과를 보여준다. 즉, top_k는 1, 3, 5로 설정해 비교하였으며, 응답의 품질에서 작은 차이를 보였다. 그럼에도 대체적인 점수가 가장 높은 3으로 top_k를 결정하였다.

이후, top_k=3으로 설정한 시스템과 기본 시스템을 비교하였다. top_k와 동일한 랜덤 고객 10명의 응답 평가 결과를 평균하여 제공한다.

4.2. 금융 자료 분석

1) 고객 및 금융 대출 데이터

본 연구에서는 고객별 맞춤 제안을 하기 위해 신한 금융그룹의 고객 데이터(일반 사용이 허용된 /공개된 데이터)를 사용하였다. 이 데이터는 신청한 현재 대출 상태, 대출 목적 등과 같은 대출 관련 정보, 부채 대비 소득 비율, 공공기록 수(과산, 세금 체납 등) 등과 같은 신용 정보 관련 정보와 연 소득과 같은 소득 정보 등이 포함되어 있다. 이러한 데이터 중에서 중복되는 정보가 있는 칼럼과 결측치 비율이 50% 이상인 칼럼은 삭제한다. 또한, 변수 간의 상관관계를 확인하여 0.7 이상인 칼럼을 필터링한다.

이때, 분석 결과의 개선을 위해 신용 점수(fico_score), 소득 대비 부채 비율(DTI), 신용 카드 사용률(credit_utilization), 월 소득(monthly_income), 대출 금액 대비 소득 비율(loan_to_income_ratio)등과 같은 파생 변수를 추가한다.

대출 거절 사유를 분석하기 위해 대출 상태를 종속 변수로 두고, 나머지 변수들을 독립 변수로 가정한다. 결과의 안정성을 위해 독립 변수들 간 강한 선형 상관관계가 있을 시 제거한다. 그리고 수치형 변수 중 다중공선성을 계산하여 수치가 높은 변수들을 제거한다. 남은 변수 중 데이터 누수 방지를 위해 대출 이후에 발생한 칼럼을 삭제한다(Kapoor, Narayanan, 2022).

최종 고객 데이터 셋은 총 77개의 변수와 약 139만 건의 고객 데이터 셋으로 구성되었으며, 고객의 신용점수, 소득 정보, 부채 비율, 대출 승인 여부를 포함하고 있다(Table 2).

Table 2. Customer data

Category	Key Variable	Description	Derived
Basic information	annual_inc	Annual income	Original
Basic information	dti	Debt-to-income ratio	Original
Basic information	fico_score	Credit score(median value)	Derived
Repayment related	loan_status	Loan status(fully paid / charged off)	Original
Repayment related	loan_to_income_ratio	Loan amount / annual income ratio	Derived
Repayment related	installment_to_income_ratio	Monthly installment/monthly income ratio	Derived
Credit related	credit_utilization	Credit utilization ratio	Derived
Others	purpose,term, etc	Loan purpose, loan term	Original

Table 3. Evaluating responses on loan denial reasons and improvement strategies

Evaluation Metric\ System	Baseline System	RAG-based System
BM25	6.71	11.67
Cosine Similarity	0.6018	0.7415
ROUGE-1	0.0557	0.1333
ROUGE-L	0.0557	0.1091
BERTScore	0.6116	0.8587

RAG에서 참조할 문서로 사용한 데이터는 총 4개로 rag-ko(Allganize, 2023a)와 financial-mmlu-ko(Allganize, 2023b), KCB 신용평가체계, 한국대부금융협회의 신용대출 매뉴얼, 핀다에서 제공한 대출 거절 솔루션을 사용했다.

Rag-ko와 financial-mmlu-ko 데이터셋은 금융 도메인의 정보와 단어들을 전문적으로 사용하기 위해 추가했다. KCB 신용평가체계, 한국대부금융협회의 신용대출 매뉴얼, 핀다에서 제공한 대출 거절 솔루션은 대출 승인 여부 및 거절 사유에 대한 응답을 전문적인 정보를 기반으로 하기 위해 추가했다.

Table 3은 대출 거부된 사람들의 대출 거절 사유와 개선 방안에 대한 응답을 평가한 결과이다. 기본 시스템의 경우 사전 정의된 규칙에 따른 문서 벡터와 질의 벡터 간 유사도를, RAG 시스템의 경우 벡터 검색을 통해 선택된 문서 벡터와 질의 벡터 간 유사도를 계산했다. 검색 성능 평가 결과, RAG 시스템은 기본 시스템(6.71) 대비 BM25 점수에서 11.67로 높은 수치로 키워드 기반 검색 알고리즘의 성능이 크게 향상되었음을 의미한다. 코사인 유사도 측정에서도, RAG 시스템은 0.7415라는 높은 수치를 기록하며 의미론적 유사성 측면에서 뛰어난 성능을 입증했다. 전통적인 규칙 기반 시스템이 단순 키워드 매칭에 의존했던 것과 달리, RAG 시스템은 더욱 고객의 상황과 맥락을 깊이 있게 이해하고 정교하고 맥락을 고려한 문서 검색을 실현하고 있다.

생성 성능 평가는 각 시스템이 생성한 응답과 금융 전문가가 작성한 참조 응답 간의 유사도를 측정하였다. ROUGE-1 지표에서 기본 시스템은 0.0557, RAG 시스템은 0.1333, ROUGE-L 지표에서 기본 시스템은 0.0557, RAG 시스템은 0.1091로 RAG 시스템은 기본 시스템 대비 약 2배 높은 점수를 보인다. 특히 ROUGE 지표가 모두 증가했다는 것을 통해 단어 수준의 일치도와 연속된 시퀀스의 유사성이 모두 향상되었음을 확인할 수 있다. BERTScore 분석 결과, RAG 시스템은 0.8587로 의미론적 유사도 측면에서 탁월한 문장 생성 능력을 보여주었다. 이는 생성된 텍스트의 일관성, 정합성, 그리고 원본 문서와의 유사성이 크게 향상되었음을 의미한다. 특히, 대출 거절 분석과 같은 복잡한 금융 영역에서 이러한 성능 개선은 매우 중요한 의미를 지닌다. 성능 평가에 사용된 응답 중 하나를 Table 4에서 확인할 수 있다.

Table 4. Comparison of baseline system and RAG-based LLM

	Baseline system	RAG-based system
Query	How can you diagnose and improve a customer's financial health?	How can you diagnose and improve a customer's financial health?
Reasoning	The customer's history of late payments, card usage, low account balances, and high interest rates indicate financial instability.	① The customer's credit score of 695 is below the minimum score of 700 recommended by most financial institutions, making it unreliable ② The high loan interest rate of 25.49% is commonly charged to customers with low credit scores and limited repayment capacity.
Improvement Strategies	① Increase card payments and manage late payments - Pay off some loans and manage interest rates ② Minimise account openings	① Improve your credit score: You should use a variety of methods to raise your credit score to 700 or higher. It is important to build your credit history by increasing your credit card usage. Currently, your credit card utilisation rate is high at 72.6%, but you may find that new accounts in the last two years, so you need to maintain your existing accounts and minimise opening new ones as much as possible ② Reduce your loan interest rate: High interest rates have made repayments more expensive. Consider the following ways to lower it:
Final Answer	Manage arrears, increase card usage to manage your credit score, reduce debt, and manage your accounts	We specifically recommend that you actively improve your credit score based on financial resources, reduce the interest rate on your loans through low-interest products, and rebuild your creditworthiness through consistent credit.

기본 시스템이 단편적이고 규칙 기반의 접근에 머물렀다면, RAG는 고객 개인의 재무 상황을 입체적으로 분석한다. 예를 들어, 단순히 “신용점수가 낮다”는 피드백을 넘어, 구체적인 신용점수 개선 전략을 제시하고, 개인의 재정 상황에 맞는 솔루션을 제안할 수 있다.

2) 금융상품 데이터

고객 데이터가 신한은행에서 제공한 데이터이기 때문에 금융상품 또한 신한은행의 금융상품으로 구성했다. 금융 회사, 금융상품명, 상품 종류, 가입대상, 상품설명으로 구성되어 있으며 총 12개의 상품이 있다. 상품 종류에는 예금, 적금, 주택청약, 펀드가 있다.

Table 5의 결과를 보면, 검색 성능 결과에서 BM25와 코사인 유사도는 9.42와 0.6353으로 모두 양호한 수치이며 관련성 높은 문서를 잘 찾았다고 판단된다. 생성 성능 결과를 보면 생성된 설명에서 문서 내 단어나 문장 구조를 그대로 인용함을 알 수 있는 ROUGE-1과 ROUGE-L은 0.0931과 0.0924로 낮은 수치임을 확인할 수 있다. 하지만 의미 기반 유사도인 BERTScore는 0.8233으로 문서 의미를 이해하고 고객 상황에 맞게 설명 재구성하였음을 알 수 있다. 추가적으로, 금융상품추천 응답의 예를 Table 6에서 확인할 수 있다.

Table 5. Evaluating responses on financial product recommendation

Evaluation Metric	RAG-based system
BM25	9.42
Cosine Similarity	0.6353
ROUGE-1	0.0931
ROUGE-L	0.0924
BERTScore	0.8233

Table 6. Example of financial product recommendation responses

	Product Name	Product Type	Key product features Name	Product Name	Product Name
Product 1	Shinhan Long-Term Treasury Bond Target Convertible Securities Investment Trust Bond	Fund	Focus on long-term blue-chip bonds, stable returns, can be redeemed mid-term	Age (35), good credit score (695), balanced risk appetite	Impact of interest rate fluctuations on returns, understand target conversion structure
Product 2	Shinhan Gold Securities Investment Trust No. 1 Stocks	Fund	Equity-based, average annual return of 8%, good for long-term investment	High income, good credit score, asset growth and portfolio diversification	Market volatility, minimum investment amount (\$1,000)
Product 3	Shinhan R.Sol Savings	Term Saving	Variable rates, minimum deposit (\$100), easy access	Upper-middle income, good credit score, money management required	Need to compare to market rates, some transaction restrictions

5. 결론

본 연구에서는 실제 대출 승인 거부 분석 사례를 이용하여 RAG 시스템의 실질적인 강점을 확인할 수 있었다. 고객의 신용점수, 소득 대비 대출 비율, 연체 이력, 신용카드 사용률 등 다양한 재무 지표를 종합적으로 분석하여 맞춤형 개선 방안을 제시했다. 단순히 대출 거절 사유를 나열하는 표준화된 응답이 아니라, 고객 개인의 구체적인 재무 상황에 기반한 심층적이고 실행 가능한 조언을 제공할 수 있었다.

특히, RAG 시스템은 신뢰도 있는 자료에 기반하여 거절 사유를 분석하고 대출 조건 개선을 위해 대출 금액 조정, 대출 기간 연장, 신용 카드 사용 및 균형 잡힌 결제 유지 등의 구체적인 방안을 제안했다. 또한, 단순한 규칙 기반이 아니라 재무 상황과 금융 도메인 데이터에 기반하여 추천 상품을 제안하고 그에 적절한 설명으로 고객에게 설득력 있는 정보를 제공했다. 이러한 성능 개선은 금융 서비스 분야에서 AI의 고객 맞춤 분석 및 피드백 능력에 대한 가능성을 열었다는 점에서 의의가 있다. 금융 서비스와 같이 개인의 고유한 상황과 전문적인 지식이 중요한 영역에서는 RAG 시스템의 중요성을 주목할 필요가 있다. 향후 연구에서는 RAG 시스템의 일반화 성능, 다양한 금융 시나리오에서의 적용 가능성, 그리고 윤리적 고려 사항 등을 더욱 깊이 탐구해야 할 것이다.

References

- AI Times (2024). Recent trends in natural language processing technology after the advent of ChatGPT, AI Times, Retrieved from <https://www.aitimes.com/news/articleView.html?idxno=165632>
- Allganize (2023a). Rag-ko [Dataset], Hugging Face. <https://huggingface.co/datasets/allganize/rag-ko>
- Allganize (2023b). Financial-mmlu-ko [Dataset], Hugging Face. <https://huggingface.co/datasets/allganize/financial-mmlu-ko>
- Business post (2024). Business post, Retrieved from https://www.businesspost.co.kr/BP?command=article_view&num=376619

- Dou, Z.-Y., Xu, Y., Wang, X. (2023). Bertscore: evaluating text generation with BERT, *Transactions of the Association for Computational Linguistics*, 11, 1-16. DOI: https://doi.org/10.1162/tacl_a_00544
- Gao, Y., Wang, X., Zhang, Z., Liu, Z., Tang, J., Han, J. (2023). Retrieval-augmented generation for large language models: a survey. arXiv preprint arXiv:2301.00375.
- Jeong, S., Hong, B. (2023). Analysis of trust formation factors in the decision-making process of financial consumers, *Journal of Consumer Studies*, 34(2), 179-203. (in Korean).
- Kang, M., Oh, K., Choi, M. (2022). Digital innovation for expanding financial inclusion: improving domestic loan screening systems, *Journal of Digital Finance*, 14(2), 87-102. (in Korean).
- Kapoor, S., Narayanan, A. (2022). Leakage and the reproducibility crisis in ML-based science. arXiv preprint arXiv:2207.07048
- Kim, D., Lee, H., Kang, M. (2023). Privacy protection mechanisms of large language models, *Journal of the Korea Institute of Information Security and Cryptology*, 33(2), 45-62. (in Korean).
- Kim, T., Lee, S. (2022). Current status and improvement plans for credit scoring models in Korean financial institutions, *Financial Research*, 36(3), 45-67. (in Korean).
- Kim, Y., Kang, C., Choi, Y. (2025). Stock price prediction using sentiment scores based on FinBERT model, *Journal of the Korean Data Analysis Society*, 27(1), 31-43. (in Korean). DOI: <https://doi.org/10.37727/jkdas.2025.27.1.31>
- Lee, C., Hwang, M., Kim, J., Lee, J., Lee, D., Kim, K. (2024a). Budget analysis in social policy using text data and financial data, *Journal of the Korean Data Analysis Society*, 26(1), 135-149. (in Korean). DOI: <https://doi.org/10.37727/jkdas.2024.26.1.135>
- Lee, J., Park, J. (2024). Latest trends in natural language processing and information retrieval, *Technical Review*, 12(1), 55-72.
- Lee, W., Park, C., Kang, S., Yoon, S. (2024b). Trend analysis of train accident-related news using topic modeling, *Journal of the Korean Data Analysis Society*, 26(6), 1739-1750. (in Korean). DOI: <https://doi.org/10.37727/jkdas.2024.26.6.1739>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W. T., Rocktäschel, T., Riedel, S., Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks, *In Advances in Neural Information Processing Systems (NeurIPS)*, 33, 9459-9474.
- Ng, J., Petrov, S. (2022). Advancing text evaluation metrics: a comprehensive analysis of ROUGE and semantic similarity, *In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, 78-95.
- No, K., Sung, B., Song, S., Song, K. (2024). Exploring the classification capabilities of large language models (LLMs) on tabular data, *In Proceedings of the Korean Data Analysis Society*, 7. (in Korean).
- Park, J., Lee, S. (2022). Enterprise AI: cloud vs on-premise strategies, *Journal of the Korean Institute of Information Scientists and Engineers*, 49(8), 112-125. (in Korean).
- Park, Y. J., Ahn, S. G., Choi, B. S. (2025). Development and application of flood vulnerability index using canonical correlation analysis, *Journal of the Korean Data Analysis Society*, 27(1), 13-29. DOI: <https://doi.org/10.37727/jkdas.2025.27.1.13>
- Reimers, N., Gurevych, I. (2019). Sentence-BERT: sentence embeddings using siamese BERT-networks, *In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982-3992.
- Robertson, S., Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond, *Foundations and Trends in Information Retrieval*, 3(4), 333-389.
- Zhang, L., Liu, P. (2022). Weighted longest common subsequence: a machine learning approach to text similarity, *International Journal of Computational Linguistics*, 33(2), 112-129.

Strategies for Enhancing Explainability in Financial Underwriting Using RAG and LLM*

Jiyeon Hong¹, Ah-Rim Joo², Sooyoung Cheon³

Abstract

Recent advances in large language models (LLMs) have significantly expanded the capabilities of natural language processing systems. In the financial domain, delivering explainable and reliable personalised feedback has become increasingly important. However, traditional rule-based loan screening systems fall short in reflecting an individual's financial context and providing actionable guidance. To address these limitations, this study proposes an LLM based loan screening system enhanced with RAG (retrieval augmented generation). The system retrieves relevant financial documents via vector-based search and feeds the context into a generative model. By leveraging external knowledge in real time, the system offers document-grounded, personalised financial recommendations. Experiments using real customer data show that the proposed RAG-based system significantly outperforms existing methods in both information retrieval and language generation. These results demonstrate the system's potential to enhance the reliability and effectiveness of personalised financial services through the integration of professional document references.

Keywords : RAG, LLM, Financial underwriting, Information retrieval, Natural language generation.

*This work was supported by the National Research Foundation of Korea(NRF) grant funded by the Korea government(MSIT) (RS-2024-00352792).

¹Undergraduate program, Division of Big Data Science, Korea University, 2511 Sejong-ro, Sejong-city, 30019, Korea. E-mail: julie2302@korea.ac.kr

²Ph.D. Candidate, Department of Economics and Statistics, Korea University, 2511 Sejong-ro, Sejong-city, 30019, Korea. E-mail: joalim@korea.ac.kr

³(Corresponding Author) Professor, Division of Big Data Science, Korea University, 2511 Sejong-ro, Sejong-city, 30019, Korea. E-mail: scheon@korea.ac.kr

[Received 31 March 2025; Revised 15 April 2025; Accepted 18 April 2025]