

SGMCMC-KF 알고리즘을 이용한 시계열 이상치 탐지*

홍지윤¹, 전수영²

요 약

실시간 스트리밍 환경에서의 시계열 이상치 탐지는 시스템 장애를 조기에 예방하고 운영 리스크를 완화하기 위해 중요하며, 이상치 탐지 연구에는 계절성과 자기상관을 반영할 수 있는 SARIMA 모형이 널리 활용된다. 그러나 기존 SARIMA는 MLE 기반 점추정에 의존하므로 파라미터 불확실성과 예측분포의 변동성을 충분히 반영하지 못해 이상치 판단의 신뢰도와 강건성에 한계가 있다. 베이지안 SARIMA는 이러한 한계를 보완할 수 있으나, 칼만필터의 예측오차 분해 기반 우도를 활용한 전통적 MCMC 추론은 스트리밍 환경에서 데이터 규모가 커질수록 계산 부담이 급격히 증가한다. 본 연구는 이를 해결하기 위해 칼만필터 기반 우도 및 기울기 계산 과정에 Gibbs 샘플링과 확률적 경사 MCMC를 결합한 SGMCMC-KF를 제안하고, 스트리밍 배치 단위로 온라인 사후추론과 예측을 수행하는 이상치 탐지 프레임워크를 제시한다. Apache Kafka 기반 스트리밍 파이프라인에서 잔차 기반 임계값 규칙과 결합하여 다양한 SGMCMC-KF 알고리즘의 탐지 성능을 비교한 결과, SGLD-KF 방법이 MLE 기반 SARIMA 대비 더 안정적인 이상치 탐지 성능을 보였으며, 특히 랑주뱅 노이즈를 통한 확률적 탐색이 스트리밍 환경에서 이상치 민감도 및 강건성 향상에 기여함을 확인하였다.

주요 용어 : 실시간 스트리밍, 이상치 탐지, SARIMA, Stochastic Gradient MCMC.

1. 서론

최근 사물인터넷(IoT), 금융 거래 시스템, 스마트 시티 인프라 등 다양한 분야에서 실시간 스트리밍 데이터의 양이 폭발적으로 증가하고 있다(Lavin, Ahmad, 2015). 이러한 환경에서 시계열 데이터의 이상치를 신속하고 정확하게 탐지하는 것은 시스템 장애 예방, 사기 거래 감지, 교통 이상 상황 파악 등 다양한 응용 분야에서 핵심적인 과제로 부상하고 있다. 실제로 최근 10년간 시계열 이상치 탐지에 관한 연구는 사이버보안, 금융, 제조업, 의료 등 광범위한 영역으로 확장되면서 급격히 증가하고 있으며(Boniol et al., 2024), 이상치 탐지 문제는 정상 데이터에 비해 이상 데이터의 발생 빈도가 낮다는 문제를 수반한다는 점도 주목받고 있다(Lee, Yeo, 2024). 특히 대용량 스트리밍 데이터를 실시간으로 처리해야 하는 온라인 이상치 탐지의 필요성이 강조되고 있다(Correia et al., 2024). 이에 따라 다양한 접근법이 제안되어 왔으나, 계절성과 자기상관 구조를 명시적으로 반영할

*이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2024-00352792). 본 논문은 2026년도 고려대학교 공공정책대학 교내지원연구비에 의해 연구되었음.

¹30019 세종시 세종로 2511, 고려대학교 빅데이터사이언스학부 석사과정. E-mail: julie2302@korea.ac.kr

²(교신저자) 30019 세종시 세종로 2511, 고려대학교 빅데이터사이언스학부 교수. E-mail: scheon@korea.ac.kr

[접수 2026년 3월 11일; 수정 2026년 3월 23일; 게재 확정 2026년 3월 26일]

수 있는 SARIMA(seasonal autoregressive integrated moving average) 계열 모형은 시계열 예측 기반 이상치 탐지에서 여전히 실무적으로 널리 활용되고 있다.

SARIMA 모형은 계절성과 추세를 효과적으로 포착할 수 있어 전통적인 시계열 이상치 탐지 방법 중 하나로 널리 활용되어 왔으며, 외생변수를 포함한 ARIMAX 계열로 확장 시 예측 정확도 향상에도 유효함이 보고되고 있다(Jang, Choi, Hwang, 2024). 그러나 기존의 SARIMA 모형은 MLE 기반의 점 추정 방식을 사용하며, 이는 다음과 같은 한계점을 가진다. 첫째, 최대우도추정(MLE) 방식은 파라미터의 불확실성을 반영하지 못한다(Gelman et al., 2013). 단일 최적 파라미터만을 추정하기 때문에 예측의 신뢰도를 정량화하기 어렵다. 둘째, 고정된 파라미터는 시간에 따라 변화하는 데이터 분포에 적응하지 못하며, 이는 실시간 스트리밍 환경에서 성능 저하로 이어질 수 있다. 셋째, MLE는 과적합에 취약하여 학습 데이터에서는 좋은 성능을 보이더라도 새로운 데이터에 대한 일반화 능력이 부족할 수 있다.

이러한 한계를 극복하기 위해 베이지안 접근법을 적용할 수 있다. 베이지안 추론은 파라미터를 확률분포로 모델링하여 불확실성을 자연스럽게 표현할 수 있으며, 사전분포를 통해 정규화 효과를 얻을 수 있다. SARIMA 모형은 상태공간 형태로 표현할 수 있으며, 이 경우 칼만 필터의 예측오차 분해를 통해 우도함수를 효율적으로 평가할 수 있다(Durbin, Koopman, 2012). 이러한 칼만 필터 기반 우도를 MCMC 샘플러와 결합하면 파라미터의 사후분포를 추론할 수 있으며, 가우시안 상태공간 모형에서 정적 파라미터의 베이지안 추론을 위한 이론적 기반이 확립되어 있다(Shephard, 1994; Carter, Kohn, 1994; Fulton, 2015). 그러나 전통적인 마코브체인 몬테카를로(Markov chain Monte Carlo, MCMC) 방법은 매 반복마다 전체 데이터에 대한 우도를 계산해야 하므로, 대용량 스트리밍 데이터에 직접 적용하기 어렵다는 문제가 있다(Brooks et al., 2011).

이를 해결하기 위해 확률적 경사 MCMC(stochastic gradient MCMC, SGMCMC) 방법들이 제안되었다. Welling, Teh(2011)가 제안한 확률적 경사 랑주뱅(stochastic gradient Langevin dynamics, SGLD) 알고리즘은 확률적 경사하강법(SGD)에 적절한 크기의 가우시안 노이즈를 추가하여, 최적화와 샘플링을 동시에 수행할 수 있음을 보였다. 이후 Chen, Fox, Guestrin(2014)은 모멘텀을 도입한 확률적 경사 해밀토니안 몬테카를로(stochastic gradient Hamiltonian Monte Carlo, SGHMC) 방법을, Ding et al.(2014)은 동적 온도 조절 메커니즘을 추가한 확률적 경사 노제-후버 서모스탯(stochastic gradient Nosé-Hoover thermostat, SGNHT) 방법을 제안하였다. 이러한 SGMCMC는 대규모 데이터 환경에서 효율적인 베이지안 추론을 가능하게 하는 방법론으로, 최근 국내 연구에서도 토픽 모델링 추론(Kim, Cheon, 2026) 등 다양한 분야에 적용되고 있다. 그러나 이러한 SGMCMC 방법들이 실시간 스트리밍 환경의 시계열 이상치 탐지에 적용된 연구는 아직 부족한 실정이다. 특히 Apache Kafka와 같은 분산 스트리밍 플랫폼을 활용한 실제적인 파이프라인에서의 성능 비교 연구는 거의 이루어지지 않았다(Kreps, Narkhede, Rao, 2011).

본 연구에서는 다양한 SGMCMC 방법들을 칼만 필터 알고리즘에 적용하여 실시간 스트리밍 환경의 베이지안 SARIMA 모형 추론을 통해 시계열 이상치 탐지를 하고자 한다. Apache Kafka 기반 스트리밍 파이프라인을 통해 시계열 데이터를 배치 단위로 수신하고, 현재 파라미터로 칼만필터 예측을 수행하여 잔차를 계산한 후, 임계값 기반 규칙으로 이상치를 판정한다. 이후 동일 배치 데이터를 사용하여 SGMCMC 방법으로 파라미터를 온라인 업데이트함으로써, 데이터 분포의 변화에 적응하면서 이상치를 실시간으로 탐지하는 프레임워크를 구성한다.

본 논문의 구성은 다음과 같다. 2장에서는 베이지안 SARIMA 모형을 소개한다. 3장에서는 이상치 탐지 프로세스를 기술하며, 4장에서는 SGMCMC-KF를 활용한 모형추론 방법을 소개한다. 5장에서는 데이터 분석결과를 보여주며, 마지막으로 6장에서는 결론과 향후 연구 방향을 제시한다.

2. 베이지안 SARIMA 모형

시계열 이상치 탐지를 위한 SARIMA 모형은 Durbin, Koopman(2012)에 따라 다음과 같이 상태공간형태로 표현할 수 있다.

$$y_t = Z\alpha_t + \epsilon_t, \quad \epsilon_t \sim N(0, H), \quad \alpha_{t+1} = T\alpha_t + R\eta_t, \quad \eta_t \sim N(0, Q).$$

여기서 y_t 는 시점 t 에서의 관측값, Z 는 관측행렬, α_t 는 시점 t 에서의 상태벡터, ϵ_t 는 시점 t 에서의 오차, T 는 상태전이행렬, R 는 선택행렬, H 는 관측오차분산, Q 는 상태오차공분산행렬이다.

n 개의 시계열 데이터 $y_1, y_2, \dots, y_n$ 이 관측되었을 때, 우도 함수 $L(\theta|y_1, \dots, y_n)$ 은 시점 t 에서 y_t 의 조건부 밀도 함수의 곱으로 표현된다(Schweppe, 1965).

$$L(\theta|y_1, \dots, y_n) = p(y_1, \dots, y_n|\theta) = \prod_{t=1}^n p(y_t|y_1, \dots, y_{t-1}, \theta), \quad \theta = (T, Z, R, H, Q).$$

초기 상태와 모든 오차항이 가우시안 분포를 따르므로, 조건부 분포 $p(y_t|y_1, \dots, y_{t-1}, \theta)$ 도 가우시안 분포를 따라 평균과 분산만으로 결정될 수 있다. Durbin, Koopman(2012)에 의해 평균과 분산은 칼만 필터의 갱신 및 예측 단계를 통해 재귀적으로 산출된다. 시점 t 의 관측값이 얻기 전에 $t-1$ 까지의 정보를 사용하여 현재 상태를 예측한다. 시점 t 에서의 예측오차는 $v_t = y_t - \hat{y}_t = y_t - \hat{Z}\hat{\alpha}_{t|t-1}$ 로 정의되며, $\hat{\alpha}_{t|t-1}$ 은 시점 $t-1$ 까지의 정보를 사용한 상태 예측값이다.

시점 t 에서의 상태 예측 평균 $\hat{\alpha}_{t|t-1}$ 은 직전 시점의 사후 추정치($\hat{\alpha}_{t|t-1} = T\hat{\alpha}_{t-1|t-1}$)로부터 구할 수 있다. 예측오차의 분산은 $F_t = ZP_{t|t-1}Z^T + H$ 이며, 여기서 $P_{t|t-1}$ 은 상태 예측오차의 공분산 행렬로 다음과 같이 이산형 리카티 방정식(discrete riccati equation)을 통해 재귀적으로 갱신된다.

$$P_{t|t-1} = T_t P_{t-1|t-2} T_t^T + R_t Q_t R_t^T.$$

이는 이전 시점의 상태 공분산이 상태전이 행렬 T_t 에 의해 전파된 불확실성과 시스템 노이즈 $R_t Q_t R_t^T$ 가 결합되어 형성되는 예측 공분산을 의미한다. 그러나 이는 실제 관측값 y_t 를 반영하기 이전의 사전 불확실성이다. 관측값이 주어지면 예측오차 v_t 를 이용하여 상태 추정을 갱신하며, 이때 칼만 이득(Kalman gain), $K_t = P_{t|t-1} Z^T F_t^{-1}$, 을 통해 예측오차를 상태 추정에 반영한다. 칼만 이득은 예측 불확실성 $P_{t|t-1}$ 과 관측 노이즈 H_t 의 상대적 크기에 따라 결정된다. 이 과정을 통해 사후 상태 추정값은 예측값에 예측오차 v_t 를 칼만 이득만큼 반영하여 상태 추정치를 보정한 $\hat{\alpha}_{t|t-1} = \hat{\alpha}_{t|t-1} + K_t v_t$ 이고, 사후공분산은 관측값을 반영함으로써 불확실성을 감소시킨 $P_{t|t-1} = (I - K_t Z) P_{t|t-1}$ 이다. 칼만 필터를 통해 계산된 예측오차 v_t 와 예측오차분산 F_t 를 이용하여 n 개의 관측값에 대한 로그우도함수 $\log p(y_1, \dots, y_n|\theta)$ 를 다음과 같이 정의할 수 있다.

$$\log p(y_1, \dots, y_n | \theta) = -\frac{1}{2} \sum_{t=1}^n \left(\log |F_t| + \frac{v_t^2}{F_t} \right) + C$$

여기서 $\log |F_t|$ 는 불확실성에 대한 패널티로, F_t 가 크면 패널티가 증가한다. v_t^2/F_t 는 정규화된 예측 오차의 제곱으로, 예측오차 v_t 가 크면 우도가 감소한다.

예측오차 v_t 와 분산 F_t 는 상태공간 행렬 $R(\theta)$ 를 통해 파라미터 θ 에 비선형적으로 의존하고, 칼만 필터의 재귀 구조에 의해 이전 시점의 상태 추정치에 연쇄적으로 의존한다. 이러한 복잡한 의존 구조로 인해 로그우도함수는 θ 에 대해 비선형이며, 최적화 기반의 MLE나 베이지안추론 방법이 필요하게 된다. MLE는 로그우도를 최대화하는 단일점 추정을 수행하지만, 파라미터의 불확실성을 반영하지 못하는 한계가 있다. 따라서 본 연구는 베이지안추론을 통해 이 문제를 해결하고자 한다.

베이지안 SARIMA 모델을 위해, 파라미터 θ 는 가우시안 사전분포 $p(\theta) = \mathcal{N}(\theta_0, \Sigma_0)$ 를 따른다고 한다. 여기서 θ_0 는 사전분포의 평균 벡터이고, Σ_0 는 사전분포의 공분산 행렬이다. 가우시안 사전분포는 정규화 효과를 제공하여 과적합을 방지하는 역할을 한다(Gelman et al., 2013). 구체적으로, $\theta_0 = 0$ 으로 설정하면 파라미터가 0에서 크게 벗어나지 않도록 하는 L2 정규화와 동등한 효과를 가지며, Σ_0 의 크기를 통해 정규화의 강도를 조절할 수 있다. 사전분포의 분산이 클수록 사전 정보의 영향이 약해져 데이터에 더 의존하게 되며, 분산이 작을수록 사전 정보의 영향이 강해진다. 따라서 파라미터 θ 의 로그 사후분포는 다음과 같다.

$$\log p(\theta | y_1, \dots, y_n) \propto -\frac{1}{2} \sum_{t=1}^n \left[\log |F_{t(\theta)}| + \mathbf{v}_{t(\theta)}^\top F_{t(\theta)}^{-1} \mathbf{v}_{t(\theta)} \right] - \frac{1}{2} (\theta - \mu_0)^\top \Sigma_0^{-1} (\theta - \mu_0). \quad (1)$$

여기서 첫째 항은 관측 데이터에 대한 적합도를 나타내며, 둘째 항은 사전분포에 의한 정규화 효과를 반영한다. 예측 오차 v_t 와 분산 F_t 는 상태공간 행렬 (T, Z, H, Q, R) 을 통해 θ 에 비선형적으로 의존하고, 칼만 필터의 재귀 구조에 의해 이전 시점의 상태 추정치에 연쇄적으로 의존한다. 이러한 비선형 의존 구조로 인해 사후분포 $p(\theta | y_1, \dots, y_n)$ 는 해석적 형태를 갖지 않으므로 사후분포로부터의 추론을 위해서는 수치적 샘플링 방법이 필요하다. 즉, 사후분포가 정규분포나 다른 알려진 분포 형태가 아니므로, 샘플링을 통해 사후분포를 근사해야 한다.

베이지안 SARIMA 모형 추론을 위해 MCMC를 이용한 칼만필터를 이용할 수 있다. 하지만, 스트리밍 환경에서는 데이터 규모 증가로 전통적 MCMC 적용이 어렵다는 제약이 존재한다. 따라서 본 연구는 이 문제를 해결하기 위해 칼만필터기반 우도/기울기함수 계산 과정에 확률적 경사 MCMC를 결합하는 방법을 제안하여 사후분포로부터 효율적인 샘플링을 수행한다.

3. 스트리밍 이상치 탐지

베이지안 SARIMA 모델을 활용한 이상치 탐지 프로세스는 다음의 네 단계로 구성된다(Figure 1). 첫째, Apache Kafka 기반 스트리밍 파이프라인을 통해 시계열 데이터를 배치 단위로 수신한다. 둘째, 수신된 배치에 대해 현재 모델로 예측을 수행하고, 예측값과 실제값 간의 잔차를 계산한다. 셋째, 잔차가 사전에 설정된 임계값을 초과하는지 판정하여 이상치를 탐지한다. 넷째, 새로운 배치 데이터를 사용하여 SGMCMC 방법으로 모델 파라미터를 온라인으로 업데이트한다. 이러한 과정을 모든 배치에 대해 반복함으로써 데이터 분포의 변화에 적응하면서 이상치를 실시간으로 탐지한다.

3.1. 실시간 데이터 수집: 스트리밍 파이프라인

실시간 스트리밍 환경을 구현하기 위해 **Apache Kafka**를 사용하였다. **Kafka**는 분산 스트리밍 플랫폼으로, 대용량 실시간 데이터 파이프라인 구축에 널리 활용된다. 본 연구에서는 배치 단위로 데이터를 스트리밍하고, 각 배치마다 모델 파라미터를 업데이트하는 온라인학습 방식을 적용하였으며, 전체 파이프라인 구성은 **Figure 1**과 같다. 배치 크기와 계절 주기는 데이터의 측정 간격과 주기적 패턴에 따라 데이터셋별로 설정한다.

3.2. 예측 및 잔차 계산

배치 b 가 도착하면, 현재 파라미터 추정값 θ_b 를 사용하여 **SARIMA** 상태공간 모형에 칼만필터를 적용하고, 배치 내 각 시점 t 에서의 예측값 $\hat{y}_t$ 를 산출한다. 상태공간 표현에서 파라미터 θ_b 는 상태 전이 행렬 T , 관측 행렬 Z , 관측 오차 분산 H , 상태 오차 공분산 Q , 선택 행렬 R 을 결정하며, 칼만필터는 이 행렬들을 사용하여 상태 벡터 a_t 를 순차적으로 예측하고 관측값 y_t 에 대한 예측값을 산출한다.

각 시점에서의 잔차는 $v_t = y_t - \hat{y}_t (= e_t)$ 와 같이 실제 관측값과 예측값의 차이로 정의된다. 이 잔차는 현재 모델이 데이터를 얼마나 잘 설명하는지를 나타내며, 비정상적으로 큰 잔차는 모델이 예상하지 못한 패턴인 이상치의 존재를 시사한다.




Figure 1. Anomaly detection pipeline with SGMCMC based SARIMA

3.3. 임계값 기반 이상치 판정

본 연구에서는 스트리밍 환경에서의 계산 효율성을 고려하여 예측값의 분포를 이용한 임계값 기반 방법으로 이상치를 판단하였다. 예측값과 실제값 간의 잔차를 이용한 임계값 기반 판정 방식은 예측 기반 이상치 탐지에서 널리 사용되는 실용적인 접근이다(Choo, Joo, Hwang, 2024). 구체적인 판정 기준은 $\hat{y}_t \leq \bar{\hat{y}} - k \cdot s_{\hat{y}} (= \hat{\mu} - k \cdot \hat{\sigma})$ or $\hat{y}_t \geq \bar{\hat{y}} + k \cdot s_{\hat{y}} (= \hat{\mu} + k \cdot \hat{\sigma})$ 이다. $\hat{y}_t$ 는 시점 t 에서의 예측값, $\bar{\hat{y}}$ 는 배치 내 예측값의 평균, $s_{\hat{y}}$ 는 배치 내 예측값의 표준편차, k 는 임계값 배수이다. 본 연구에서는 미세한 이상 패턴까지 탐지하기 위해 비교적 민감한 임계값인 $k=1$ 을 사용하였다. 예측값이 평균에서 표준편차의 1배 이상 벗어나면 이상치로 판정하는 방식이다. 배치 내에서 하나 이상의 시점이 이상치로 판정되면 해당 배치를 이상치 배치로 분류한다.

3.4. 온라인 파라미터 업데이트

업데이트된 파라미터 θ_{t+1} 은 다음 $t+1$ 의 예측에 사용되므로 파라미터 업데이트 방식에 따라 이상치 탐지 특성이 달라진다. GD와 SGD는 점 추정 방식으로 파라미터가 단일 값으로 수렴하여 이상치 경계 부근에서 탐지가 제한될 수 있다. 반면 SGMCMC(SGLD, SGHMC, SGNHT)는 노이즈를 통해 사후분포를 탐험하므로 예측에 다양성이 생기고, 이는 경계 부근의 이상치도 탐지할 가능성을 높인다. 이러한 업데이트 방법의 차이가 배치마다 누적되어 최종 이상치 탐지 성능에 영향을 미친다.

4. SGMCMC-KF 알고리즘을 이용한 베이지안 SARIMA 모형 추론

4.1. SGMCMC 알고리즘

SGMCMC는 전체 데이터 우도 대신 확률적으로 근사된 기울기와 인위적 노이즈를 결합하여 대규모 데이터 환경에서도 베이지안 사후분포 샘플링을 가능하게 하는 MCMC 계열 알고리즘으로, 그 중에서 SGLD는 랑주뱅 동역학에 기반한 샘플링 방법이다(Welling, Teh, 2011). 연속 시간에서의 랑주뱅 동역학은 $d\theta = \nabla \log P(\theta|D)dt + \sqrt{2T}dW_t$ 이며 브라운운동 W_t 와 온도 T 를 고려한다. 이를 오일러-마루야마(Euler-Maruyama) 방법으로 이산화하면 다음과 같은 식을 얻을 수 있다.

$$\theta_{t+1} = \theta_t + \epsilon \cdot \nabla \tilde{U}(\theta_t) + \sqrt{2\epsilon T} \cdot \eta_t, \quad \eta_t \sim N(0, I).$$

SGLD의 핵심은 기울기 업데이트에 적절한 크기의 랑주뱅 노이즈를 추가하는 것이다. 이를 통해 최적화와 샘플링을 동시에 수행할 수 있으며, $\epsilon \rightarrow 0$ 일 때 정확한 사후분포 샘플링이 가능하다. 노이즈 항 $\sqrt{2\epsilon T} \cdot \eta_t$ 는 파라미터 공간의 탐험을 촉진하여 지역 최솟값을 탈출하는 데 도움을 주는 동시에 파라미터의 불확실성을 자연스럽게 반영할 수 있게 한다. GD나 SGD와 달리 단일 점 추정이 아닌 사후분포로부터의 샘플을 생성하므로, 예측 불확실성의 정량화가 가능하다.

SGHMC는 해밀토니안 동역학(Hamiltonian dynamics)에 기반한 샘플링 방법으로 모멘텀을 도입하여 수렴을 가속화한다(Chen, Fox, Guestrin, 2014). 해밀토니안 동역학은 다음과 같이 정의된다.

$$H(\theta, p) = U(\theta) + \frac{1}{2} r^T M^{-1} r.$$

여기서 $H(\theta, p)$ 는 위치 에너지 $U(\theta)$ 와 운동 에너지 $r^T M^{-1} r/2$ 의 합으로 구성된다. 또한 r 는 모멘텀 벡터이고, M 은 질량 행렬로 본 연구에서는 단위 행렬 I 를 사용하였다. 마찰과 노이즈를 포함한 이산화된 업데이트 규칙은 다음과 같다.

$$\theta_{t+1} = \theta_t + r_{t+1}, \quad r_{t+1} = (1 - \alpha\epsilon)r_t + \epsilon \cdot \nabla \tilde{U}(\theta_t) + \sqrt{2\alpha\epsilon T} \cdot \eta_t, \quad \eta_t \sim \mathcal{N}(0, I).$$

모멘텀 업데이트에서 α 는 마찰 계수로 에너지 소산을 담당하고, ϵ 은 학습률, T 는 온도, η_t 는 표준 가우시안 노이즈이다. 모멘텀 r 는 기울기 방향으로 가속하여 수렴 속도를 높이고, 마찰 항 $1 - \alpha\epsilon$ 는 에너지 소산을 통해 시스템을 안정화한다. 노이즈 항은 SGLD와 마찬가지로 파라미터 공간의 탐색을 촉진하여 사후분포로부터의 샘플링을 가능하게 한다. 모멘텀의 도입으로 강한 상관관계를 가진 파라미터 공간에서도 효율적인 탐색이 가능하지만, 마찰 계수 α 와 질량 행렬 M 등 추가적인 하이퍼파라미터 조정이 필요하다.

SGNHT는 동적마찰계수 ξ 를 도입하여 시스템의 온도를 자동으로 조절한다(Ding et al., 2014).

$$p_{t+1} = p_t + \epsilon \cdot \nabla \tilde{U}(\theta_t) - \epsilon \xi_t p_t + \sqrt{2A\epsilon} \cdot \eta_t, \quad \xi_{t+1} = \xi_t + \epsilon(p_{t+1}^T p_{t+1}/d - T), \quad \theta_{t+1} = \theta_t + \epsilon \cdot p_{t+1}.$$

여기서 모멘텀 업데이트에서 ξ 는 서모스탯 변수로 동적마찰계수 역할을 하며, A 는 확산계수(diffusion coefficient)이다. 서모스탯 업데이트에서 d 는 파라미터 차원이고, T 는 목표온도이다. $p_{t+1}^T p_{t+1}/d$ 는 현재 운동 에너지를 나타내며, 운동 에너지가 목표 온도 T 보다 높으면 ξ 가 증가하여 마찰이 커지고 시스템이 감속한다. 반대로 운동 에너지가 낮으면 ξ 가 감소하여 마찰이 줄어들고 시스템이 가속한다. 이러한 피드백 메커니즘을 통해 정준분포를 유지하며, SGHMC에서 마찰 계수를 수동으로 조정해야 하는 문제를 해결한다.

4.2. SGMCMC-KF 알고리즘을 이용한 베이지안 SARIMA 모델 추론

칼만 필터에 사용되는 MCMC는 매 반복마다 전체 데이터에 대해 우도를 계산해야 하므로 대용량 스트리밍 데이터에 적용하기 어렵다. SGMCMC는 전체 데이터 대신 부분 데이터에 기반한 확률적 기울기를 사용하고, 여기에 가우시안 노이즈를 추가함으로써 사후분포로부터 샘플링을 수행함으로써 이 문제를 해결한다.

2.1절에서 정의한 로그 사후분포 (1), $\log p(\theta|y_1, \dots, y_n)$, 를 에너지 함수 $U(\theta)$ 로 표현할 수 있다. 다양한 SGMCMC 알고리즘들은 이 에너지 함수의 기울기를 이용하여 파라미터를 갱신한다.

$$\begin{aligned} \nabla U(\theta) &= -\nabla \log P(D|\theta) - \nabla \log P(\theta) = -\nabla \log P(D|\theta) + \Sigma_0^{-1}(\theta - \mu_0) \\ &= \frac{1}{2} \sum_{t=1}^T \left[\text{tr} \left(F_t^{-1} \frac{\partial F_t}{\partial \theta} \right) - v_t^T F_t^{-1} \frac{\partial F_t}{\partial \theta} F_t^{-1} v_t + 2v_t^T F_t^{-1} \frac{\partial v_t}{\partial \theta} \right] + \Sigma_0^{-1}(\theta - \mu_0). \end{aligned}$$

이러한 상태공간 모형의 로그우도 기울기는 칼만필터 재귀와 병렬로 계산될 수 있으며, 가우시안 상태공간 모형에서의 표준적인 결과이다(Harvey, 1989). 위 수식에서 $\partial v_t / \partial \theta$ 와 $\partial F_t / \partial \theta$ 를 구하려면

$t-1$ 시점의 상태에 의존하는 재귀 구조를 가지므로, 기울기 계산에는 칼만필터가 필수적이다. 본 연구에서는 statsmodels 라이브러리의 model.score 함수를 사용하여 기울기를 계산하였다(Seabold, Perktold, 2010; Statsmodels developers, 2024).

SGMCMC-KF 알고리즘: 반복 t 에서의 알고리즘은 다음과 같다.

1. 초기 파라미터 θ_0 를 설정한다.
2. 시점 t 까지의 최근 스트리밍 데이터로 구성된 배치 데이터 D_t 를 구성한다.
3. 칼만필터링방법을 이용하여, 현재 θ_t 로 부터 각 시점에서의 예측오차 $v_i (i \in D_t)$ 와 예측오차 분산 $F_i (i \in D_t)$ 를 계산한다.
4. SGMCMC 알고리즘을 통해 파라미터를 갱신한다. (예: SGLD)
 - (a) 배치 데이터 D_t 를 사용하여 에너지 함수와 그 기울기를 계산한다.

$$\tilde{U}(\theta) = \frac{N}{2n} \sum_{i \in D_t} U_i(\theta), \quad U_i(\theta) = \log p(\theta | y_i), \quad i \in D_t.$$

$$\nabla \tilde{U}(\theta) = \frac{N}{2n} \left[\frac{1}{2} \sum_{i \in D_t} \left[\text{tr} \left(F_i^{-1} \frac{\partial F_i}{\partial \theta} \right) - v_i^T F_i^{-1} \frac{\partial F_i}{\partial \theta} F_i^{-1} v_i + 2v_i^T F_i^{-1} \frac{\partial v_i}{\partial \theta} \right] + \Sigma_0^{-1}(\theta - \mu_0) \right].$$

- (b) 계산된 기울기를 이용하여 SGLD 업데이트 규칙에 따라 파라미터를 갱신한다.

$$\theta_{t+1} = \theta_t - \epsilon_t / 2 \nabla \tilde{U}(\theta_t) + \sqrt{\epsilon_t} \eta_t, \quad \eta_t \sim N(0, I).$$

5. 새로운 데이터에 대해 2-4 과정을 반복하여 파라미터를 온라인으로 업데이트한다.

이 구조에서 칼만필터 자체는 기존 MLE 추정과 동일하게 작동한다. 차이점은 칼만필터가 반환한 기울기를 어떻게 사용하여 θ 를 갱신하는가에 있다. MLE는 로그우도를 최대화하는 단일 파라미터 추정을 수행하는 반면, SGMCMC는 기울기에 적절한 노이즈를 추가하여 사후분포로부터 샘플링을 수행한다. 한편, SARIMA 모형의 파라미터는 AR/MA 계수의 안정성 조건과 분산의 양수 제약 등 다양한 제약 조건을 만족해야 한다. 이러한 제약 조건 하에서 비제약 최적화 방법인 SGMCMC를 적용하기 위해, statsmodels에서 제공하는 파라미터 변환 메서드(transform_params, untransform_params)를 활용하였다 (Seabold, Perktold, 2010; Statsmodels developers, 2024). 이 프레임워크는 AR/MA 계수에 대해 tanh 변환과 Durbin-Levinson 재귀를 적용하고, 분산 파라미터에 대해 제곱 변환을 적용하여 비제약 공간 $\psi \in \mathcal{R}^d$ 에서 기울기 업데이트를 수행한 후 제약 공간으로 역변환함으로써 모든 제약 조건을 자동으로 만족시킨다.

5. 데이터 분석

NAB(Numenta Anomaly Benchmark)는 Ahmad et al.(2017)이 제안한 벤치마크 데이터베이스로, 58개의 실제 및 인공 시계열 데이터와 스트리밍 환경에 특화된 평가 체계를 제공한다. Ahn, Kim, Lee(2021)는 동일 데이터셋에서 MLE 기반 SARIMA가 NYC taxi와 machine temperature 데이터 모두

F1-점수 0을 보고하였으며, Saran, Hasan(2025)은 베이지안 ARIMA 기반 탐지를 연구하였으나 계절성 모델링과 구체적인 베이지안 추론 방법을 제시하지 않았다. 본 연구에서는 이러한 한계를 극복하기 위해 계절성을 포함한 SARIMA 모델에 다양한 SGMCMC 방법을 적용하여 베이지안 노이즈가 이상치 탐지 성능에 미치는 영향을 체계적으로 비교한다.

본 연구에서는 전통적 MCMC 기반 비교 방법으로 Gibbs 샘플링을 포함하여, GD, SGD, SGLD, SGHMC, SGNHT 방법을 SARIMA 모델에 적용하여 이상치 탐지 성능을 비교하였다. 분류 성능 평가를 위해 혼동행렬 기반의 정확도(accuracy), 정밀도(precision), 재현율(recall), F1-점수와 같은 평가지표를 계산하였다. 실시간 스트리밍 환경에서는 각 배치의 도착 간격 내에 예측과 파라미터 업데이트가 완료되어야 하므로, 배치당 처리 시간 또한 측정하여 함께 비교한다.

SARIMA 모델의 설정은 AR 차수 0, 차분 차수 1, MA 차수 1, 계절 AR 차수 1, 계절 차분 차수 1, 계절 MA 차수 0, 계절 주기는 각 데이터셋의 측정 간격에 따라 달리 설정하였다. 각 방법별 하이퍼파라미터는 예비 실험을 통해 최적값을 탐색하였다. 학습률은 모든 방법에서 1.0×10^{-5} 로 동일하게 설정하여 공정한 비교가 가능하도록 하였다. 온도는 노이즈의 크기를 조절하는 파라미터로, SGLD와 SGHMC에서는 0.1을 사용하여 적절한 탐험이 이루어지도록 하였고, SGNHT에서는 1.0×10^{-6} 으로 설정하여 안정적인 수렴을 유도하였다. SGD의 노이즈 스케일은 0.1, SGHMC의 마찰 0.1, SGNHT의 확산계수는 1.0을 사용하였다. SGHMC와 SGNHT는 모멘텀 기반 방법으로 수렴에 더 많은 반복이 필요하여 배치당 에포크(epoch) 수를 3으로 설정하였다. 반면 GD, SGD, SGLD는 1 에포크만으로 충분한 성능을 보였다. 또한 모멘텀 기반 방법에서는 모멘텀의 크기가 1.0을 초과하지 않도록 클리핑(clipping)을 적용하여 수치적 안정성을 확보하였다. 본 연구에서는 훈련(train) 데이터와 테스트(test) 데이터를 분리하여 각 방법의 성능을 평가하였다.

5.1. NYC taxi 데이터

NAB의 NYC taxi 데이터셋은 실시간 스트리밍 환경에서의 이상치 탐지 알고리즘을 평가하기 위해 Lavin, Ahmad(2015)가 발표한 벤치마크 데이터베이스이다. NAB는 인공 데이터와 실제 데이터를 포함하며, 각 데이터셋에 대해 전문가가 레이블링한 이상치 정보를 제공한다.

NYC taxi 데이터셋은 뉴욕시 택시 승객 수를 30분 간격으로 측정한 시계열 데이터이다. 2014년 7월부터 2015년 1월까지 약 6개월간의 데이터로 구성되어 있으며, 총 10,320개의 데이터 포인트를 포함한다. 이 데이터셋에는 NYC 마라톤, 추수감사절, 크리스마스, 신년 등 특별한 이벤트로 인한 이상치가 포함되어 있어 실시간 이상치 탐지 알고리즘의 성능을 평가하기에 적합하다. 본 연구를 위해 전체 데이터를 8:2 비율로 분할하였고, 계절 주기는 48로 설정하여 일별 주기성을 반영하여 훈련 데이터는 172개 배치, 테스트 데이터는 43개 배치로 구성된다. Table 1은 데이터셋의 구성을 나타낸다. 훈련 데이터에서 이상치가 포함된 배치는 124번과 150번이며, 테스트 데이터에서는 6번, 13번, 39번 배치에 이상치가 포함되어 있다.

Table 1. The composition of NYC taxi dataset

Category	Number of samples	Number of batches	Anomalous batches
Train	8,256	172	[124, 150]
Test	2,064	43	[6, 13, 39]
Total	10,320	215	5




Figure 2. NYC taxi dataset time series plot

Figure 2는 NYC taxi 데이터셋의 시계열 그래프를 나타낸다. 데이터는 명확한 일별 주기성을 보이며, 주중과 주말의 패턴 차이도 관찰된다. 그래프에서 네모는 최대값, 세모는 최소값, 원은 이상치를 나타낸다. 약 6,000번째 타임스탬프(timestamp) 근처에서 약 40,000명에 달하는 급격한 승객 수 증가가 관찰되며, 이는 NYC 마라톤, 크리스마스 등과 같은 특별 이벤트로 인한 것이다. 또한 10,000번째 타임스탬프 근처에서는 승객 수가 거의 0에 가깝게 감소하는 현상이 관찰되는데, 이는 신년 연휴 등의 영향으로 추정된다. 이러한 급격한 변화들이 이상치로 레이블링되어 있으며, 본 연구의 목표는 이러한 이상치를 실시간으로 탐지한 것이다.

1일 데이터가 48개의 포인트로 구성되기 때문에 계절 주기를 48로 설정하였고, 이를 통해 일별 패턴을 효과적으로 학습할 수 있다. Table 2는 훈련 데이터에서 각 방법별 성능을 나타낸다. 분석 결과, SGLD가 정밀도 3.70%, F1-점수 7.14%를 기록하며 가장 우수한 성능을 보였으며, 재현율 100%를 달성하여 두 이상치 배치를 모두 탐지했다. SGNHT(6.56%), SGD(6.35%), GD(6.15%) 역시 재현율 100%를 달성하며 비교적 높은 F1-점수를 나타냈다. 반면, SGHMC와 Gibbs는 재현율이 50%에 그치며 탐지 안정성이 상대적으로 낮았다. 이는 SGHMC의 경우 모멘텀 기반 업데이트로 인해 탐지 임계값 주변에서 변동성이 커질 수 있기 때문으로 볼 수 있다. 또한 각 방법의 배치 처리 시간이 배치 도착 간격보다 충분히 짧게 유지되어, 제안된 방법이 실시간 스트리밍 환경에서도 적용 가능함을 확인하였다.

Table 3은 테스트 데이터에서 각 방법별 성능을 나타낸다. 테스트 데이터에는 3개의 이상치 배치(6, 13, 39번)가 포함되어 있다. 테스트 데이터 분석 결과에서 SGLD가 정밀도 9.38%로 가장 높았으며, 재현율 100%를 달성하여 F1-점수 17.14%를 기록하였다. SGHMC는 F1-점수 18.18%로 SGLD보다 근소하게 높게 측정되었으나, 총 3개의 실제 이상치 중 2개를 미탐지하여 재현율이 33.33%에 그쳤다. 이상 탐지 도메인의 특성상 치명적인 이상치를 놓치지 않는 것이 핵심이므로, 단순 F1-점수보다 재현율 100%를 달성한 SGLD가 탐지 안정성과 불확실성 대응 측면에서 실질적으로 가장 우수한 방법론이라 평가할 수 있다. GD, SGD, SGNHT 역시 재현율 100%를 달성하였으나 정밀도와 F1-점수 모두 SGLD에 비해 낮은 수준에 머물렀다. Gibbs와 SGHMC는 높은 정확도를 보였으나 재현율 저하로 인해 이상 탐지 관점에서는 신뢰성이 낮다고 볼 수 있다.

Table 2. The results of NYC taxi train dataset

Method	Accuracy(%)	Precision(%)	Recall(%)	F1(%)	Time(s)
MLE	64.33	3.17	100	6.15	20.6
Gibbs	81.29	3.12	50	5.88	170.8
GD	64.33	3.17	100	6.15	27.5
SGD	65.50	3.28	100	6.35	34
SGLD	69.59	3.70	100	7.14	31
SGHMC	73.68	2.22	50	4.26	41.6
SGNHT	66.67	3.39	100	6.56	41.0

Table 3. The results of NYC taxi test dataset

Method	Accuracy(%)	Precision(%)	Recall(%)	F1(%)	Time(s)
MLE	19.05	8.11	100	15.00	9.8
Gibbs	64.29	7.14	33.33	11.76	83.3
GD	21.43	8.33	100	15.38	11.1
SGD	19.05	8.11	100	15.00	10.9
SGLD	30.95	9.38	100	17.14	10.6
SGHMC	78.57	12.50	33.33	18.18	10.7
SGNHT	64.29	8.33	100	15.38	10.6

Table 4. The composition of machine temperature system failure dataset

Category	Number of samples	Number of batches	Anomalous batches
Train	18,156	378	[51, 84, 342]
Test	4,539	94	[29]
Total	22,695	472	4

5.2. Machine temperature system failure 데이터

Machine temperature system failure 데이터는 NAB에 포함된 시계열 데이터 중 하나로, 실시간 스트리밍 환경에서의 이상치 탐지 알고리즘을 평가하기 위해 Lavin, Ahmad(2015)가 제안한 벤치마크 데이터베이스이다. 데이터셋은 단일 기계에 장착된 온도 센서의 측정값을 시간 순서대로 기록한 단변량 시계열 데이터로 온도 값은 5분 간격으로 수집되었다. 총 22,695개의 데이터 포인트를 갖고 있으며, 장기간의 정상 운전 상태에서 나타나는 비교적 안정적인 패턴과 함께 시스템 이상 및 최종적인 시스템 실패로 이어지는 비정상적인 온도 변화 구간을 포함한다. 본 연구에서는 전체 데이터를 8:2 비율로 분할하였으며 5분 간격 측정으로 인해 1시간에 12개의 데이터 포인트가 생성되므로 계절 주기를 12, 배치 크기를 48(4시간 분량)로 설정하여 기계 작동 사이클 단위의 온도 변화 패턴을 반영하도록 하였다. 이에 따라 훈련 데이터는 378개 배치, 테스트 데이터는 94개 배치로 구성되며, Table 4와 같이 구성됨을 볼 수 있다.

해당 데이터에는 네 개의 이상치가 포함되어 있다. 51번 배치(2013-12-11)는 계획된 정지로 인한 급격한 온도 하강, 84번 배치(2013-12-16)는 복구 과정의 비정상적 온도 변화, 342번 배치는 이후 치명적 고장의 전조가 되는 미세한 패턴 변화, 테스트의 29번 배치는 급격한 온도 상승 후 시스템 완전 정지에 해당한다. Figure 3은 machine temperature 데이터셋의 시계열 그래프를 나타내며, 그래프에서 네모는 최대값, 세모는 최소값, 원은 이상치를 나타낸다. 모델 구현에는 Python의 statsmodels(Seabold, Perktold, 2010) 라이브러리를 사용하였다.

Table 5는 훈련 데이터에서 각 방법별 성능을 나타낸다. MLE, GD, SGD, SGLD, SGHMC는 모든 이상치를 탐지하여 재현율이 100%로 나타났지만, SGNHT와 Gibbs는 재현율이 66.67%에 그쳐 일부 이상치를 탐지하지 못하였다. 훈련 데이터 분석결과에서 SGLD가 가장 높은 정확도(32.28%), 정밀도(1.16%), F1-점수(2.29%)를 기록하며 전반적으로 가장 우수한 성능을 보였다. SGNHT는 정확도 52.38%로 높게 나타났으나 재현율이 66.67%에 그쳐 이상치 미탐지가 발생하였고, F1-점수(2.17%) 또한 SGLD에 비해 낮았다. MLE, GD, SGD, SGHMC는 재현율 100%를 달성하였으나 정확도 (17.72%), 정밀도(0.96%), F1-점수(1.89%) 모두 동일한 수준에 머물며 SGLD에 비해 낮은 탐지 성능을 보였다. Gibbs는 재현율 66.67%에 F1-점수 1.35%로 가장 낮은 성능을 나타냈다. 이는 SGLD가 확률적 샘플링을 통해 예측 불확실성을 효과적으로 반영함으로써 테스트 데이터에서도 안정적인 탐지 성능을 유지한 반면, 점 추정 기반의 GD와 SGD는 탐지 경계 부근에서 변별력이 낮아질 수 있기 때문으로 해석할 수 있다.




Figure 3. Time series plot of machine temperature system failure dataset

Table 5. The results of machine temperature system failure train dataset

Method	Accuracy(%)	Precision(%)	Recall(%)	F1(%)	Time(s)
MLE	17.72	0.96	100	1.89	10.6
Gibbs	22.49	0.68	66.67	1.35	18.6
GD	17.72	0.96	100	1.89	11.0
SGD	17.72	0.96	100	1.89	11.1
SGLD	32.28	1.16	100	2.29	11.0
SGHMC	17.72	0.96	66.67	1.89	10.9
SGNHT	52.38	1.10	100	2.17	11.0

Table 6. The results of machine temperature system failure test dataset

Method	Accuracy(%)	Precision(%)	Recall(%)	F1(%)	Time(s)
MLE	29.79	1.49	100	2.94	10.6
Gibbs	30.85	0.00	0	0.00	18.6
GD	25.53	1.41	100	2.78	11.0
SGD	29.79	1.49	100	2.94	11.1
SGLD	34.04	1.59	100	3.12	11.0
SGHMC	25.53	1.41	100	2.78	10.9
SGNHT	26.60	1.43	100	2.82	11.0

Table 6은 테스트 데이터에서 각 방법별 배치 단위 성능을 나타낸다. 데이터에는 1개의 이상치 배치(29번)가 포함되어 있으며 모든 방법이 해당 이상치를 잡아냈다. 분석 결과에서 SGLD가 가장 높은 정확도(34.04%), 정밀도(1.59%), F1-점수(3.12%)를 기록하며 전반적으로 가장 우수한 성능을 보였다. MLE와 SGD는 정확도 29.79%, F1-점수 2.94%로 동일한 수준을 유지하며 그 뒤를 이었고, SGNHT(2.82%), GD와 SGHMC(2.78%) 역시 재현율 100%를 달성하며 비교적 안정적인 탐지 성능을 보였다. Gibbs는 정확도 30.85%로 준수한 수준이었으나 정밀도, 재현율, F1-점수가 모두 0.00%로 나타나 실질적인 이상치 탐지에 완전히 실패하였다. 이는 Gibbs 샘플링이 해당 데이터셋에서 이상치 탐지 임계값을 전혀 초과하지 못했기 때문으로 해석할 수 있다. 전반적으로 SGLD를 포함한 SGMCMC 계열 방법들이 확률적 샘플링을 통해 불확실성을 반영함으로써 안정적인 탐지 성능을 유지한 반면, Gibbs는 배치 단위 이상 탐지에서 한계를 드러냈다.

한편, 본 연구의 이상치 판정 방식이 배치 내 예측값의 평균과 표준편차만을 기준으로 하기 때문에 정밀도가 낮게 나타났다. 현재 방식에서는 예측값 자체의 변동만으로 임계값을 설정하므로, 모델의 예측이 조금이라도 불안정한 구간에서 정상 배치가 이상치로 과다 판정되는 경향이 있다. 특히 배치 내 48개 시점 중 하나만 임계값을 초과해도 해당 배치 전체가 이상치로 분류되는 배치 단위 판정 방식이 거짓양성을 증가시키는 요인으로 작용한다.

6. 결론

본 연구에서는 SGMCMC 방법들을 실시간 스트리밍 환경의 베이지안 SARIMA 모델에 적용하여 시계열 이상치 탐지 성능을 비교 분석하였다. NAB의 NYC taxi와 machine temperature 데이터로 Apache Kafka 기반 스트리밍 파이프라인을 사용하여 칼만필터 기반 Gibbs 샘플링을 포함하여 GD, SGD, SGLD, SGHMC, SGNHT, 여섯 가지 방법을 평가하였다. 분석 결과, SGLD가 모든 다른 방식 대비 정확도와 거짓양성 측면에서 전반적인 성능 개선을 보이며 가장 안정적인 탐지 성능을 나타냈다. 노이즈가 없는 GD와 약한 노이즈만 포함하는 SGD는 테스트 데이터에서 제한적인 이상치 탐지 성능을 보인 반면, 랑주뱅 노이즈를 사용하는 SGLD는 더 많은 이상치 배치를 탐지하여 노이즈의 효과를 확인할 수 있었다. 이는 적절한 노이즈가 파라미터 공간의 탐색을 촉진하여 다양한 패턴의 이상치를 포착하는 데 도움을 줄 수 있음을 시사한다. 또한 제안한 SGLD 기반 방법은 비교적 낮은 계산 비용으로 안정적인 이상치 탐지 성능을 보이며, 실시간 스트리밍 환경에서도 적용 가능한 효율적인 베이지안 추론 방법임을 확인하였다.

모멘텀 기반 방법인 SGHMC도 일정 수준의 탐지 성능을 보였으나, 안정적인 수렴을 위해 배치당 추가 에포크가 필요하여 실시간 처리 속도가 저하되었다. SGNHT는 서모스탯의 동적 마찰 조절이 스트리밍 환경에서 불안정하게 작동하여 기대만큼의 성능을 보이지 못하였다. 따라서 실시간 스트리밍 환경에서는 구현이 간단하면서도 효과적인 SGLD가 가장 적합한 방법임을 확인하였다.

본 연구의 한계점으로는 우선 현재의 임계값 기반 판정 방식이 예측값의 통계량만을 사용하는 단순한 접근으로, 정밀도가 전반적으로 낮은 한계를 보였다는 점을 들 수 있다. 또한 하이퍼파라미터 최적화가 충분히 이루어지지 않아 각 방법의 최적 성능을 도출하지 못했을 가능성이 있으며, 두 개의 NAB 데이터셋에서만 검증이 이루어져 금융·의료 등 상이한 도메인으로의 일반화 가능성이 제한적이라는 점도 한계로 남는다.

향후 연구에서는 현재의 고정 임계값($k=1$) 방식을 개선하여, 칼만 필터가 매 시점마다 재귀적으로 산출하는 예측오차분산 F_t 를 활용한 적응적 임계값 설정 방안을 검토할 필요가 있다. 정규화된 예측오차 $v_t/\sqrt{F_t}$ 가 정상 상태에서 근사적으로 표준정규분포를 따른다는 성질을 이상치 판정에 직접 활용하면, 모델 불확실성이 높은 구간에서는 임계값을 완화하고 안정 구간에서는 강화하는 적응적 판정이 가능해져 거짓양성을 효과적으로 줄일 수 있을 것으로 기대된다. 아울러 적응 학습률을 적용하여 수렴 안정성을 개선하고, 앙상블 방법을 통해 탐지 성능을 향상시키는 연구와 함께 금융 거래, 의료 생체신호 등 상이한 도메인의 시계열 데이터셋에 추가 적용하여 본 프레임워크의 외적 타당성과 일반화 가능성을 체계적으로 검증하는 연구가 필요하다. 이는 베이지안 추론의 장점인 불확실성 정량화를 이상치 탐지에 활용하는 방향이 될 것이다.

References

- Ahmad, S., Lavin, A., Purdy, S., Agha, Z. (2017). Unsupervised real-time anomaly detection for streaming data, *Neurocomputing*, 262, 134-147.
- Ahn, J., Kim, J., Lee, B. (2021). Semi-supervised time series anomaly detection based on statistics and deep learning, *Applied Sciences*, 11(15), 6698.
- Boniol, P., Liu, Q., Huang, M., Palpanas, T., Paparrizos, J. (2024). Dive into time-series anomaly detection: a decade review, *arXiv preprint arXiv:2412.20512*.
- Brooks, S., Gelman, A., Jones, G., Meng, X.-L. (2011). *Handbook of Markov chain Monte Carlo*, Chapman and Hall/CRC.
- Carter, C. K., Kohn, R. (1994). On Gibbs sampling for state space models, *Biometrika*, 81(3), 541-553.
- Chen, T., Fox, E. B., Guestrin, C. (2014). Stochastic gradient Hamiltonian Monte Carlo, *Proceedings of the 31st International Conference on Machine Learning (ICML)*, Beijing, China.
- Choo, C., Joo, H., Hwang, E. (2024). Time series analysis for prediction intervals of electricity demand with weather variables, *Journal of the Korean Data Analysis Society*, 26(2), 471-488. (in Korean). <https://doi.org/10.37727/jkdas.2024.26.2.471>
- Correia, L., Goos, J.-C., Klein, P., Bäck, T., Kononova, A. V. (2024). Online model-based anomaly detection in multivariate time series: taxonomy, survey, research challenges and future directions, *Engineering Applications of Artificial Intelligence*, 138, 109323.
- Ding, N., Fang, Y., Babbush, R., Chen, C., Skeel, R. D., Neven, H. (2014). Bayesian sampling using stochastic gradient thermostats, *Advances in Neural Information Processing Systems*, 27, 3203-3211.
- Durbin, J., Koopman, S. J. (2012). *Time series analysis by state space methods* (2nd ed.), Oxford University Press, Oxford.
- Fulton, C. (2015). *Estimating time series models by state space methods in Python: Statsmodels*, Unpublished.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., Rubin, D. B. (2013). *Bayesian data analysis* (3rd ed.), Chapman and Hall/CRC, Boca Raton.
- Harvey, A. C. (1989). *Forecasting, structural time series models and the Kalman filter*, Cambridge University Press, Cambridge. <https://doi.org/10.1017/CBO9781107049994>
- Jang, J., Choi, S., Hwang, E. (2024). Time series analysis for the number of drug offenders under 20s using ARIMAX-Threshold model, *Journal of The Korean Data Analysis Society*, 26(4), 1015-1031. (in Korean). <https://doi.org/10.37727/jkdas.2024.26.4.1015>
- Kim, D., Cheon, S. (2026). Inference of transfer network topic model using AWSGLD, *Journal of The Korean Data Analysis Society*, 28(1), 109-121. (in Korean).

- Kreps, J., Narkhede, N., Rao, J. (2011). Kafka: a distributed messaging system for log processing, Proceedings of the NetDB Workshop, Athens, Greece.
- Lavin, A., Ahmad, S. (2015). Evaluating real-time anomaly detection algorithms: The Numenta anomaly benchmark, Proceedings of the 14th International Conference on Machine Learning and Applications (ICMLA).
- Lee, K., Yeo, D. (2024). Support vector machines with reject option for unequal costs and imbalanced datasets, Journal of The Korean Data Analysis Society, 26(6), 1689-1705. (in Korean). <https://doi.org/10.37727/jkdas.2024.26.6.1689>
- Saran, T., Hasan, R. (2025). Anomaly on the fly: streaming anomaly detection in supervised learning, International Conference on Information Technology: New Generations (ITNG 2025), Las Vegas, USA.
- Schweppe, F. C. (1965). Evaluation of likelihood functions for Gaussian signals, IEEE Transactions on Information Theory, 11(1), 61-70.
- Seabold, S., Perktold, J. (2010). Statsmodels: econometric and statistical modeling with Python, Proceedings of the 9th Python in Science Conference (SciPy), Austin, Texas.
- Shephard, N. (1994). Partial non-Gaussian state space, Biometrika, 81(1), 115-131.
- Statsmodels developers. (2024). Statsmodels: Statistical modeling and econometrics in Python. <https://www.statsmodels.org>
- Welling, M., Teh, Y. W. (2011). Bayesian learning via stochastic gradient Langevin dynamics, Proceedings of the 28th International Conference on Machine Learning (ICML), Bellevue Washington USA.

Time Series Anomaly Detection Using the SGMCMC-KF Algorithm^{*}

Jiyeon Hong¹, Sooyoung Cheon²

Abstract

Detecting anomalies in real-time streaming time series is crucial for early prevention of system failures and mitigation of operational risks. The SARIMA model, which captures seasonality and autocorrelation, is widely used for this task. However, conventional SARIMA relies on MLE based point estimation and cannot adequately account for parameter uncertainty and variability in predictive distributions, limiting the reliability and robustness of anomaly detection. Bayesian SARIMA can address this limitation, but traditional MCMC inference-including Gibbs sampling-based on Kalman filter prediction error decomposition becomes computationally expensive as data scale increases in streaming environments. To address this issue, this study proposes SGMCMC-KF, which combines stochastic gradient MCMC with Kalman filter-based likelihood and gradient computations, and evaluates its performance against Gibbs sampling and MLE-based SARIMA. Experiments in an Apache Kafka-based streaming pipeline show that the SGLD-KF method achieves more stable anomaly detection performance, and that stochastic exploration via Langevin noise improves anomaly sensitivity and robustness in streaming environments.

Keywords : Real-time Streaming, Anomaly Detection, SARIMA, Stochastic Gradient MCMC.

^{*}This work was supported by the National Research Foundation of Korea(NRF) grant funded by the Korea government (MSIT) (RS-2024-00352792). This article is financially supported by the 2026 College of Public Policy at Korea University.

¹Master's Course, Division of Big Data Science, Korea University, 2511 Sejong-ro, Sejong-city, 30019, Korea. E-mail: julie2302@korea.ac.kr

²(Corresponding Author) Professor, Division of Big Data Science, Korea University, 2511 Sejong-ro, Sejong-city, 30019, Korea. E-mail: scheon@korea.ac.kr

[Received 11 March 2026; Revised 23 March 2026; Accepted 26 March 2026]