

합성데이터 활용 식품 TBT 위반 탐지

기술장벽(TBT)과 데이터 불균형 문제 해결을 위한 접근

고려대학교 일반대학원 빅데이터사이언스학과
홍지윤

목차

1 연구 배경
식품 TBT 현황, 데이터 불균형

2 TBT 협정의 맥락
연구 위치, 규제 vs 장벽

3 TBT의 실체
기술규정, 표준, 적합성평가

4 데이터 분석
한국 식품 2,493개, 1:63 불균형

5 연구 방법론
3단계 파이프라인, 합성데이터

6 실험 결과
성능 향상, Feature Importance

7 품질 검증
판별 테스트, 상관계수, KS/PSI

8 한계 및 시사점
검증 필요성, 제도적 함의

9 결론
가능성과 한계, Q&A

연구 배경

핵심 문제

식품 TBT는 라벨링 규정에서 가장 빈번하게 발생

데이터 불균형

실제 TBT 위반 사례는 전체의 1.6%에 불과
→ AI 학습이 구조적으로 어려운 상황

각국의 라벨링 규제

미국 FDA, EU Nutri-Score, 중국 GB 7718
→ 국가별 요구사항이 모두 달라 사전 예측 어려움


연구 질문

"데이터가 희귀한 상황에서
합성데이터로 TBT 위험을 예측할 수 있는가?"

접근 방식

합성데이터를 통한 구조적 문제 해결

연구 배경



같은 제품, 같은 성분이라도 국가마다 다른 형식으로 다시 입증해야 함

연구 배경

정당한 규제

소비자 보호, 공중보건 목적

예: 알레르기 표시 의무화

?

사실상 장벽

불필요한 무역제한 초래

예: 동일 내용, 다른 형식 요구

장벽으로 전환되는 지점

동일 목적, 다른 기준
중복 적합성평가 초래

데이터/보고 형식 차이
실질적 비용 발생

같은 내용 반복 입증
기업 부담 가중

TBT 협정은 규제를 금지하지 않지만, **형식의 파편화**가 사실상의 무역장벽으로 작동



기술규정
Technical Regulations



표준
Standards



적합성평가
Conformity Assessment

식품 라벨링의 중요성

"라벨 하나가 통관을 막을 수 있음"

사전 대응 실패 → 통관 거부 → 비용 손실

비관세장벽으로서의 TBT

- 국가별 상이한 라벨링 요구사항
- 중복 적합성평가로 인한 비용 증가
- 기업의 사전 예측 어려움
- 관세보다 실질적 무역장벽으로 작용

데이터 분석 : 한국 식품 라벨링 현황

분석 대상

2,493개

Open Food Facts 한국 식품

TBT 위험 제품

39개 (1.6%)


영어 라벨 부재

클래스 불균형

1:63

학습 어려운 구조

카테고리별 GAP 비율 히트맵



유제품, 스낵류가 위험 비율 높음

"데이터가 없는 상황에서 어떻게 위험을 예측할 것인가"라는 근본적인 질문에서 출발

01

희귀 사례 학습의 한계

전통적인 머신러닝은 충분한 학습 데이터를 전제
->발생 빈도가 낮은 케이스는 이 전제가 성립 X

02

규제 데이터의 구조적 특성

규제 위반 데이터는 본질적으로 불균형함
대부분 제품은 규정을 준수, 위반은 예외적 상황

03

합성데이터의 가능성

부족한 실제 데이터를 보완하기 위해 인공적으로 생성된 데이터가 현실적인 대안이 될 수 있는지
검증 필요

연구 방법론

Phase 1

데이터 전처리

Open Food Facts 데이터
한국 식품 필터링
영양정보 추출 및 정제

Phase 2 - Track 1

생성형 AI

Solar-pro LLM 활용
FDA 규격 라벨 생성
JSON에서 이미지 변환

Phase 3 - Track 2

예측형 AI (핵심)


AdsGAN 합성데이터
Random Forest 분류
TBT 위험 탐지

연구 목표

- 합성데이터로 식품 TBT 위반을 탐지할 수 있는가?
- 데이터 불균형 문제 해결
- 예측 모델 성능 향상

트랙 1

생성형 AI : FDA 규격 라벨 자동 생성



자동 생성 항목

Nutrition Facts

Calories, Fat, Sodium, Carbs, Protein

Allergen Statement

Contains: Milk, Soy, Gluten 등 자동 식별

Marketing Claims

No Artificial Flavors, Low Sugar 등

생성 결과 예시

```
product_name_en:
  Red Bean and Cream Bread
calories_per_serving:
  102 kcal
allergen_statement:
  Contains: Milk, Soy
```

Pillow 라이브러리로 FDA 표준 이미지 생성

트랙 1

생성형 AI : FDA 규격 라벨 자동 생성



Nutrition Facts	
Serving size: 30g	
Amount per serving	
Calories	102
Total Fat	3.9g
Sodium	86mg
Total Carbohydrate	15.1g
Protein	1.6g

INGREDIENTS INFO:
Contains: Milk, Soy (Inferred from 'Cream' ingredient)

Product: Red Bean & Cream Bread

트랙 2

합성 데이터 생성 및 학습

문제: 학습 불가능한 데이터 구조

2,493개 중 위험 샘플 단 39개 → 모델이 위험 패턴을 학습할 수 없음



단순 오버샘플링

같은 39개를 복사해도 패턴은 동일
과적합(Overfitting) 위험 증가
새로운 정보량 증가 없음

합성데이터 (AdsGAN)

원본 분포를 학습하여 새 샘플 생성
변수 간 상관관계 유지
다양한 위험 패턴 생성 가능

"구조적 문제"를 해결하는 접근 → 위험 데이터의 통계적 특성을 학습하여 증폭

트랙 2

합성 데이터 생성 및 학습

GAN 아키텍처



합성 데이터 생성 : AdsGAN 모델


- 데이터의 분포를 학습
- 테이블 데이터에 특화된 구조
- 연속형/범주형 혼합 데이터 처리
- 소규모 데이터에서도 안정적 학습

실험 환경


GPU	라이브러리	학습	생성
RTX 4080	SynthCity	300 epochs	3,000개

증강 결과

원본 2,493 to 증강 후 5,493



to



Track 2

합성 데이터 생성 및 학습

성능 결과

Accuracy (정확도)

87% to 96% +10%p

F1 Score (위험 탐지)

0.06 to 0.08 +33%p

최종 모델 정확도

92.63%

결과 해석

정확도 향상

합성데이터가 모델의 전반적인 예측 능력을 크게 향상시킴

소수 클래스 탐지 개선

기존에 거의 탐지 불가능했던 위험 클래스 인식 능력 확보

핵심 성과

합성데이터가 불균형 문제를 효과적으로 해결했음을 입증

분석 결과:

핵심 위험 요인 분석

1 당류 (sugars)
중요도: 0.2086

20.9%

규제 직관과 일치

각국의 식품 규제는 고당류, 고칼로리, 고지방 식품에 엄격한 기준 적용

2 에너지 (energy)
중요도: 0.1971

19.7%

해석 가능한 결과

모델이 학습한 패턴이 실제 규제 논리와 부합하여 결과에 대한 신뢰성 확보

3 지방 (fat)
중요도: 0.1918

19.2%

실무적 시사점

당류/에너지/지방 함량이 높은 제품은 TBT 위험 가능성이 높으므로 사전 점검 필요

합성 데이터 한계

⚠ 성능 개선은 신뢰성 확보가 아님

합성데이터는 어디까지나 원본의 근사치일 뿐

검증이 필요한 질문들

진짜 위험 제품과 유사한가?

분포가 왜곡되지 않았는가?


변수 간 관계가 유지되는가?

필요한 검증 방법

- 1 분포 유사성 (KS test, Wasserstein)
- 2 변수 관계 유지 (상관계수 비교)
- 3 합성 판별기 테스트 (AUROC)

검증 없는 합성데이터 활용은 또 다른 위험을 만들 수 있다

합성 데이터 판별 테스트




판별 정확도: 55.7%
랜덤(50%)과 거의 차이 없음

의미
Logistic Regression이 원본과 합성을 구분하지 못함

결론
합성 데이터가 원본과 통계적으로 유사함을 입증

합성 데이터 판별 테스트



패턴 일치

원본과 합성의 상관계수 구조가 거의 동일

차이 미미

대부분 변수에서 차이가 0.1~0.3 수준

핵심 관계 보존

energy-fat 상관: 0.771 vs 0.721

합성 데이터 판별 테스트

원본 vs 합성 데이터 통계적 검증 결과

변수	KS 통계량	Wasserstein 거리	PSI
Energy_100g	0.0856	20.3273	0.0563
Fat_100g	0.2148	2.9411	0.2246
Sugars_100g	0.2669	1.8949	0.0414
Proteins_100g	0.18	1.9237	0.0449
Sodium_100g	0.1534	0.3168	0.0011

KS 통계량

0.08~0.27 수준으로 실질적 차이 작음
(0.3 미만 OK)

PSI (안정성 지수)

대부분 0.25 미만으로 분포 안정적
(업계 기준 충족)

결론

합성 데이터가 원본 분포를 충실히 재현

합성 데이터 판별 테스트

원본 vs 합성 데이터 통계적 검증 결과

변수	KS 통계량	Wasserstein 거리	PSI
Energy_100g	0.0856	20.3273	0.0563
Fat_100g	0.2148	2.9411	0.2246
Sugars_100g	0.2669	1.8949	0.0414
Proteins_100g	0.18	1.9237	0.0449
Sodium_100g	0.1534	0.3168	0.0011

KS 통계량

0.08~0.27 수준으로 실질적 차이 작음
(0.3 미만 OK)

PSI (안정성 지수)

대부분 0.25 미만으로 분포 안정적
(업계 기준 충족)

결론

합성 데이터가 원본 분포를 충실히 재현

결과

형식 불일치

같은 제품이라도 데이터 형식이 다르면 다시
검증해야 함

FDA 형식 ≠ EU 형식 ≠ 중국 형식

중복 평가

동일 내용을 여러 방식으로 입증해야 하는
비효율

CAP 비용 증가 → 사실상 기술장벽

해결 방향

국제표준 기반 측정·보고 체계 공통화

트랙 1도 이 문제의식에서 출발

AI가 "위험하다"고 판정해도, 규제기관이 받아들이지 않으면 의미가 없다 → 제도적 합의 필요

결론

검증된 성과

1:63 to 1:1

불균형 해결

87% to 96%

정확도 향상

55.7%

판별 정확도 (유사성 입증)

PSI 0.25 미만

분포 안정성 확보

연구의 의의

합성데이터로 극단적 불균형 문제 해결 가능
품질 검증을 통해 신뢰성까지 확보

남은 과제

- 절대적 F1 Score 추가 개선 필요
- 더 큰 규모의 데이터로 검증 확대
- 제도적 합의

결론

검증된 성과

1:63 to 1:1

불균형 해결

87% to 96%

정확도 향상

55.7%

판별 정확도 (유사성 입증)

PSI 0.25 미만

분포 안정성 확보

연구의 의의

합성데이터로 극단적 불균형 문제 해결 가능
품질 검증을 통해 신뢰성까지 확보

남은 과제

- 절대적 F1 Score 추가 개선 필요
- 더 큰 규모의 데이터로 검증 확대
- 제도적 합의

감사합니다