

No.

NUMBERING

환경에 따른 최적 작물 예측

[통계학과 머신러닝 PBL]

2021380518 홍지윤, 2021380547 김다연, 2022380529 장연서

No.

CONTENTS

[통계학과 머신러닝 PBL]

01 Topic

-주제 선정 동기 및 목표

02 데이터 및 전처리

-데이터 소개
-데이터 전처리

03 EDA

-데이터 EDA

04 머신러닝 모델

-머신러닝 모델 socre
-모델 선택
-CONFUSION MATRIX

05 결과

- PARTIAL DEPENDENCE PLOTS
- VALUE MAPPING

06 결론

-결론
-보완할 점

01

CHAPTER

Topic

주제 선정 동기 및 목표

01

Topic

주제 선정 과정

" 환경에 따른 최적 작물 예측 "

[두터운 농가 경영안전망 확충 필요]

작물 생산 실패로 인한 농가 경영비 증가를 최소화할 수 있도록 선행 사례 분석을 통한 최적 환경정보 제공 필요성 대두

[지속가능한 농업을 위한 환경 친화적 생태계 조성]

최적의 작물 환경 정보를 제공함으로써 물, 비료, 농약 등의 자원 사용을 최소화 하고 지속가능한 농업환경 구축에 도움을 줄 수 있을 것이라 판단

목 표

**" 농업 생산성 향상을 위한
환경 조건에 기반한 최적 작물 예측 정보 제공 "**

02

CHAPTER

데이터 및 전처리

-데이터 소개
-데이터 전처리

02 DATA

데이터

출처 : 농촌진흥청

- [품목]
- 파프리카
 - 방울토마토
 - 완숙토마토
 - 참외
 - 국화
 - 딸기
 - 오이

[원본 데이터]

A	B	C	D	E	F	G	H	I	J
품목	풍향	풍속	일사량	누적일사량	강우감지	온도	상대습도	잔존CO2	토양온도
파프리카		2	1	997	0	21	49.8	494	
파프리카		3.7	1	998	0	21	49.6	491	
파프리카		4.2	0	998	0	20.9	47.9	486	
파프리카		0.9	0	998	0	21	47.7	478	
파프리카		2.8	1	998	0	21	48.7	480	
파프리카		2.2	0	998	0	21.1	48.7	478	
파프리카		1.2	0	998	0	21.7	47.8	478	
파프리카		1.3	3	998	0	22	47.3	483	
파프리카		2.8	31	12	0	22.2	46.1	487	
파프리카		1.7	145	67	0	22.2	46.8	490	
파프리카		1.3	267	163	0	23.5	50.3	489	
파프리카		1.8	372	300	0	24.8	50.9	638	
파프리카		1.8	524	489	0	28	40.4	729	
파프리카		2.2	518	675	0	29.1	37.7	750	

827080 * 10

환경 변수 : 풍향, 풍속, 일사량, 누적일사량, 강우감지, 온도, 상대습도,
잔존 CO2, 토양온도

데이터 전처리

[품목]

- 파프리카
- 방울토마토
- 완숙토마토
- 참외
- 국화
- 딸기
- 오이

[데이터]

A	B	C	D	E	F
품목	풍속	일사량	온도	상대습도	잔존CO2
파프리카	2.1	1	21	49.8	494
파프리카	3.7	1	21	49.6	491
파프리카	4.2	0	20.9	47.9	486
파프리카	0.9	0	21	47.7	478
파프리카	2.8	1	21	48.7	480
파프리카	2.2	0	21.1	48.7	478
파프리카	1.2	0	21.7	47.8	478
파프리카	1.3	3	22	47.3	483
파프리카	2.8	31	22.2	46.1	487
파프리카	1.7	145	22.2	46.8	490
파프리카	1.3	267	23.5	50.3	489
파프리카	1.8	372	24.8	50.9	638
파프리카	1.8	524	28	40.4	729
파프리카	2.2	518	29.1	37.7	750

↓

공통된
환경변수만 추출

827080 * 6

환경 변수 : 풍속, 일사량, 온도, 상대습도, 잔존 CO2

02

DATA

데이터 전처리

[데이터 수정]

```
# 1. 품목이 '국화'인 행 제거  
df = df[df['품목'] != '국화']  
  
# 2. 품목이 '완숙토마토'인 행 제거  
df = df[df['품목'] != '완숙토마토']  
  
# 3. 랜덤 데이터를 15000개 추가  
num_new_rows = 15000
```



품목	데이터 수
딸기	46952
파프리카	63646
방울토마토	79295
참외	15695
오이	18604
랜덤	15000

- 국화
: 결측치가 多
- 완숙토마토
: 특정 환경이 뚜렷하지 않음
- 랜덤
: 예측 결과 확인 시 5개의 작물과 적합하지 않는 작물을 분류하기 위해 클래스 추가 생성

데이터

최종 사용 데이터

[Data Information]

```
df.info()
```

#	Column	Count	Non-Null	Dtype
0	품목	239192	non-null	object
1	풍속	239192	non-null	float64
2	일사량	239192	non-null	float64
3	온도	239192	non-null	float64
4	상대습도	239192	non-null	float64
5	잔존CO2	239192	non-null	float64

dtypes : float64(5), object(1)

$239192 * 6$

- 각 데이터의 개수 및 타입 확인

03

CHAPTER

EDA


데이터 특성 확인

03 DATA EDA

Categorical plot

sns.pairplot을 이용하여 품목별
환경 변수 간 상관관계 시각화

-> 각 작물의 최적 성장 환경 확인




03 DATA EDA

Categorical plot

온도와 일사량은 0.58의 상관관계

=> 온도가 높을수록 일사량이
높아지는 경향이 있음

다른 기능들은 서로 낮은 상관관계에서
중간 정도의 상관관계가 나타남



03

DATA EDA

Categorical plot

풍속 Requirement

파프리카 1.1529601231813469

딸기 0.9730895382518316

오이 0.9243012255428941

참외 0.8784899649569926

방울토마토 0.8104836370515165

0

0.5

1

[MEAN]

가장 높은 요구 작물: 파프리카 (1.1530), 딸기 (0.9731)

가장 낮은 요구 작물: 방울토마토 (0.8105), 참외 (0.8785)

∴ 파프리카와 딸기는 풍속이 강한 환경에서 잘 자라며,
방울토마토와 참외는 상대적으로 풍속이 약한 환경에서 잘 자람

03

DATA EDA

Categorical plot



[MEAN]
가장 높은 요구 작물: 오이 (176.8429), 방울토마토 (169.4760)
가장 낮은 요구 작물: 파프리카 (141.9004), 딸기 (152.9842)
∴ 오이와 방울토마토는 일사량이 높은 환경에서 잘 자라며, 파프리카와 딸기는 상대적으로 일사량이 낮은 환경에서 잘 자람

03

DATA EDA

Categorical plot

온도 Requirement



[MEAN]

가장 높은 요구 작물: 참외 (24.0092), 파프리카 (21.7200)

가장 낮은 요구 작물: 딸기 (16.5361), 방울토마토 (19.4985)


∴ 참외와 파프리카는 온도가 높은 환경에서 잘 자라며,
딸기와 방울토마토는 상대적으로 낮은 온도에서 잘 자람

03

DATA EDA

Categorical plot

상대습도 Requirement



[MEAN]


가장 높은 요구 작물: 방울토마토 (87.6333), 파프리카 (86.3509)

가장 낮은 요구 작물: 참외 (77.9492), 딸기 (81.9997)

∴ 방울토마토와 파프리카는 습도가 높은 환경에서 잘 자라며,
참외와 딸기는 상대적으로 낮은 습도에서 잘 자람

03
DATA EDA

Categorical plot



[MEAN]
가장 높은 요구 작물: 참외 (716.8243), 오이 (556.4866)
가장 낮은 요구 작물: 방울토마토 (439.1596), 파프리카 (484.5316)
∴ 참외와 오이는 토양의 잔존 CO2 농도가 높은 환경에서 잘 자라며, 방울토마토와 파프리카는 상대적으로 낮은 CO2 농도에서 잘 자람

04

CHAPTER

머신러닝 모델

-머신러닝 모델 socre

-모델 선택

-CONFUSION MATRIX

04 MODELING

DATASET
SPLITTING

소수 클래스 기준 언더샘플링
& Target variable을 '품목'으로



[언더샘플링]

```
# 소수 클래스의 데이터 기준 언더샘플링하기
df = df.groupby('품목').apply(lambda x: x.sample
                               (n=min_class_count, random_state=42)).reset_index(drop=True)

Y = df['품목']
encode = preprocessing.LabelEncoder()
y = encode.fit_transform(Y)
```

품목	데이터 수
딸기	15000
파프리카	15000
방울토마토	15000
참외	15000
오이	15000
랜덤	15000

TRAIN : TEST
= 0.75 : 0.25

04

MODELING

머신러닝 모델

[DECISION TREE]

-> 환경 변수와 작물 성장 간 관계
쉽게 이해 가능

[SVM]

-> 다양한 환경 변수와 작물 성장 간
복잡한 관계 모델링 가능

[K-NN CLASSIFIER]

-> 환경 변수에 대한 품목들을 비교해
예측 가능

[BAGGING]

-> 다양한 데이터셋에 잘 작동하며,
과적합을 줄이는 데 효과적

[RANDOM FOREST]

-> 다양한 데이터셋에 대해 높은
정확도 제공, 특성의 중요도 평가
가능

[LGBM]

-> 높은 학습 속도와 효율성, 적은
메모리 사용량, 크고 복잡한
데이터셋에서도 우수한 성능

04

MODELING

머신러닝 모델

Model	f-1 score
Decision Tree	0.6140
SVM	0.3973
K-NN Clasifier	0.5338

전처리 후



Model	f-1 score
Decision Tree	Train : 0.9999 Test : 0.7500
SVM	Train : 0.5082 Test : 0.5128
K-NN Clasifier	Train : 0.9961 Test : 0.6328

전처리 전의 기본 데이터에 비해 전처리 후 데이터의 모델 score이 높은 것으로 보아 적절한 전처리가 이뤄졌다고 판단 가능


04 MODELING

Decision Tree

정확도 좋은 모델
Confusion Matrix 확인

- '참외'가 가장 높은 정밀도와 재현율
- '방울토마토'는 다른 클래스에 비해 성능 ↓

	precision	recall	f1-score	support
딸기	0.66	0.65	0.66	3752
랜덤	1.00	1.00	1.00	3679
방울토마토	0.61	0.61	0.61	3764
오이	0.72	0.74	0.73	3702
참외	0.82	0.84	0.83	3810
파프리카	0.67	0.67	0.67	3793



04

MODELING

머신러닝 모델

[DECISION TREE]

Train f1 score : 0.9999
Test f1 score : 0.7500

[SVM]

Train f1 score : 0.5082
Test f1 score : 0.5128

[K-NN CLASSIFIER]

Train f1 score : 0.9961
Test f1 score : 0.6328

[BAGGING]

Train f1 score : 0.9835
Test f1 score : 0.8178

[RANDOM FOREST]

Train f1 score : 0.9979
Test f1 score : 0.7918

[LGBM]

Train f1 score : 0.8416
Test f1 score : 0.8108

04

MODELING

Bagging / Randomforest / LGBM

[Bagging]

```
pipe1 = make_pipeline(preprocessing.StandardScaler(),  
                      RandomForestClassifier(n_estimators=100))  
# 모델 학습  
bag_model = BaggingClassifier(base_estimator=pipe1,  
                              n_estimators=100, oob_score=True,  
                              random_state=0, max_samples=0.8)  
  
bag_model.fit(X_train, y_train)  
bag_model.score(X_test, y_test)  
predict = bag_model.predict(X_test)
```

Train F1 score: 0.9835
Test F1 score: 0.8178

[Randomforest]

```
# 랜덤 포레스트 모델 학습  
rf_model = RandomForestClassifier(  
    n_estimators=100, random_state=42)  
  
rf_model.fit(X_train, y_train)  
  
# Predicting on the train set  
y_train_pred = rf_model.predict(X_train)  
  
# Predicting on the test set  
y_test_pred = rf_model.predict(X_test)
```

Train F1 score: 0.9979
Test F1 score: 0.7918

[LGBM]

```
# LightGBM 모델 생성  
lgb_model = lgb.LGBMClassifier(random_state=0)  
  
# 모델 학습  
lgb_model.fit(X_train, y_train)  
  
# Predicting on the train set  
y_train_pred = lgb_model.predict(X_train)  
  
# Predicting on the test set  
y_test_pred = lgb_model.predict(X_test)
```

Train F1 score: 0.8416
Test F1 score: 0.8108

"세 개의 모델 中 Train, Test score의 차이가 가장 작음"




04 MODELING

LGBM

정확도 좋은 모델
Confusion Matrix 확인
(최종 모델)

- '참외'가 가장 높은 정밀도와 재현율
- '방울토마토'는 다른 클래스에 비해 성능 ↓

	precision	recall	f1-score	support
딸기	0.75	0.70	0.73	3668
랜덤	1.00	1.00	1.00	3692
방울토마토	0.68	0.71	0.69	3743
오이	0.81	0.77	0.79	3887
참외	0.89	0.92	0.90	3782
파프리카	0.73	0.76	0.75	3728



05

CHAPTER

결과

- PARTIAL DEPENDENCE PLOTS
 - VALUE MAPPING
-

05 RESULT


Feature Importance

LGBM

* gain : LGBM에서 기본적으로 사용되는 feature importance 계산 방법

가장 높은 중요도: 온도 (414508.501)

가장 낮은 중요도: 풍속 (73434.053)




05

RESULT

Partial Dependence Plots

Partial Dependence Plots 딸기



온도

10°까지 상승할 때, '딸기'의 예측 확률이 급격히 증가
10°를 넘어가면 확률이 감소

일사량

일사량이 증가함에 따라 처음에는 '딸기'에 대한 예측 확률이 약간 감소
이후 점차 증가하며 일사량이 높을수록 '딸기' 등급이 나올 확률이 증가

잔존
CO2

잔존 CO2가 약 500ppm까지 증가하면서 '딸기'에 대한 예측 확률 증가
이후 일반적으로 높은 수준을 유지

습도

약 30%까지 '딸기'의 예측 확률이 급격히 증가하여 약 30%때 정점
이후 습도가 높아질수록 확률이 꾸준히 감소

풍속


비교적 평탄한 추세로
다른 특징에 비해 예측에 미치는 영향이 크지 않음

05

RESULT

Partial Dependence Plots

Partial Dependence Plots 방울토마토



온도

10°에서 15°로 상승할 때, '방울토마토'의 예측의 확률이 급격히 증가
15°를 넘어가면 확률이 급격히 감소

일사량

약간의 변동을 보이지만 비교적 안정적으로 유지
일사량이 예측에 미치는 영향이 크지 않음

잔존
CO2

잔존 CO2가 약 400ppm까지 급격히 증가하다가 이후에는 크게 감소

습도

습도가 증가함에 따라 '방울토마토'에 대한 예측 확률이 꾸준히 증가
60% 이상에서 급격히 상승

풍속


약 1m/s까지 감소한 후 뚜렷한 추세 없이 약간의 변동이 있음
풍속이 다른 특징에 비해 예측에 미치는 영향이 크지 않음

05

RESULT

Partial Dependence Plots

Partial Dependence Plots 오이



온도

약 15°까지 올라갈수록 '오이'에 대한 예측 확률이 크게 증가
이후에는 확률이 약간 변동하다가 25° 이후부터 감소

일사량

일사량이 증가함에 따라 '오이'에 대한 예측 확률이 증가하여
약 200-300 j/cm2로 정점을 찍음

잔존
CO2

잔존CO2가 낮을 때 '오이'에 대한 예측 확률이 높고
약 500ppm까지 감소하다 이후 다시 상승

습도

다양한 습도 수준에서 비교적 안정적으로 유지
습도가 다른 특징에 비해 '오이' 예측에 미치는 영향이 크지 않음

풍속


약 1.5m/s까지 증가함에 따라 '오이'에 대한 예측 확률이 증가

05

RESULT

Partial Dependence Plots

Partial Dependence Plots 참외



온도

온도가 증가함에 따라 증가하며, 약 25°를 넘을 때 급격히 증가

일사량

약 100 j/cm² 이후 '참외'에 대한 예측 확률 값이 감소하는 경향

잔존
CO2

잔존CO2 농도가 약 400ppm부터 600ppm까지 급격히 증가 후 점진적으로 증가

습도

상대습도가 특정 범위 내에서 변동하지만, 전반적으로 큰 변화가 없음

풍속


약 1m/s까지 높은 예측 확률을 보이지만 이후 급격히 하락하면서 낮은 예측 확률을 보임

05

RESULT

Partial Dependence Plots

Partial Dependence Plots 파프리카



온도

약 15°까지 올라갈수록 '파프리카'에 대한 예측 확률이 크게 증가
이후에는 약간의 변동과 함께 확률이 안정화

일사량

약 100 j/cm²까지 급격히 감소한 후 확률 비교적 일정

잔존
CO2

낮은 잔존CO2에서 '파프리카'에 대한 예측 확률이 높고
CO2 수준이 약 500ppm까지 감소하다 약간의 변동 후 일반적으로
낮은 수준을 유지

습도

상대 습도 약 20%까지 급격히 증가 후 안정화

풍속

풍속이 증가할 수록 예측 확률이 조금씩 증가
큰 변화가 없음

05

RESULT

Value Mapping

여러 번 예측 실행

predictions = []

envs = []

for _ in range(100): # 예측을 100번 반복

 predicted_item, env_dict = predict_item()

 predictions.append(predicted_item)

 envs.append(env_dict)

 print(f"환경변수: {env_dict}, 예상 품목: {predicted_item}")

환경변수: {'풍속_외부': 4.2218990137480015, '일사량_외부': 369.161131380573.5751872200976}, 예상 품목: 참외

환경변수: {'풍속_외부': 2.402187387997503, '일사량_외부': 815.2689642548636.9966267636253}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 1.380689641788887, '일사량_외부': 57.946012195592': 453.7460780209093}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 4.139875375906453, '일사량_외부': 195.89187423942': 944.2123740594134}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 4.39861434843097, '일사량_외부': 776.64570286260390.8416040812043}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 7.314359513414221, '일사량_외부': 906.21734858102': 701.7562640605938}, 예상 품목: 랜덤작물


환경변수: {'풍속_외부': 6.7221759859091215, '일사량_외부': 590.6215792732': 877.4366096189541}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 9.275350728134097, '일사량_외부': 308.8438922742555.6262284185523}, 예상 품목: 랜덤작물

환경변수: {'풍속_외부': 3.6053633355518757, '일사량_외부': 459.013906718703.6978271314063}, 예상 품목: 딸기



예측된 작물 분포



06

CHAPTER

결론

- SUMMARY

- 보완할 점

06 결론

Conclusion

Summary

" 환경에 따른
최적 작물 예측 "

데이터

환경 및 품목 데이터

환경 : 풍속, 일사량, 온도, 상대습도, 잔존 CO2

품목 : 딸기, 방울토마토, 오이, 참외, 파프리카

Target variable : 품목

Train : Test = 0.75 : 0.25

최종 모델

"LGBM"

Train f1 score : 0.8416

Test f1 score : 0.8108

- '참외'가 가장 높은 정밀도와 재현율
- '방울토마토'는 다른 클래스에 비해 성능 ↓

06 결론

Conclusion

Summary

" 환경에 따른
최적 작물 예측 "

Feature Importance

가장 높은 중요도 : 온도 (414508.501)

가장 낮은 중요도 : 풍속 (73434.05)

Parital Dependance

- 딸기 : 온도 변화에 큰 영향, 적정 습도,
높은 잔존CO2 필요

- 방울토마토 : 적정 온도와 잔존CO2, 높은 습도

- 오이 : 적정 온도, 매우 높거나 낮은 잔존 CO2

- 참외 : 높은 온도와 잔존CO2, 약한 풍속

- 파프리카 : 낮은 잔존CO2와 일사량, 높은 온도

Value Mapping

100번의 mapping 中 대부분의 값이 랜덤 클래스로 분류
=> 반복 수 증가 시 고른 분포로 될 것

06

결론

추가 보완할 점

[작물 데이터 필요]

Value mapping 에서 확인했듯이
값을 분포별로 골고루 적용하였지만,
랜덤 환경 변수의 범위가 넓어 대부분의 값이
랜덤 (그 외의 값)으로 나오는 것을 확인


=> 더 다양한 작물 데이터 필요

[환경 데이터 필요]

풍속, 일사량, 온도, 상대습도, 잔존 CO2만으로
작물에 적절한 환경인지 파악할 수 있나에 대한
의문

추가 환경 변수 (토양 및 환경 정보) 데이터를
통한 더욱 정확한 분류 필요

=> 다양한 환경 정보 데이터 필요



감사합니다